电子科技大学
University of Electronic Science and Technology of China

第2-3章
高维优化基础

高维优化基础

本节我们先了解一些高维函数的相关概念：

1. 水平集
2. 梯度、黑塞矩阵
3. 二次型、正定矩阵
4. 高维函数泰勒展开式
5. 可行方向以及方向导数
6. 极值点的必要条件

水平集

- 函数$f:\mathbb{R}^n \to \mathbb{R}$在$c$上的水平集(或等值线)定义为：

$$S = \{\boldsymbol{x}: f(\boldsymbol{x}) = c\}$$

对于$f:\mathbb{R}^2 \to \mathbb{R}$,水平集为曲线；对于$f:\mathbb{R}^3 \to \mathbb{R}$，水平集S通常是一组曲面。

如：$f(x_1, x_2) = 100(x_2 - x_1^2)^2 + (1 - x_1)^2, \boldsymbol{x} = [x_1 . x_2]^T$

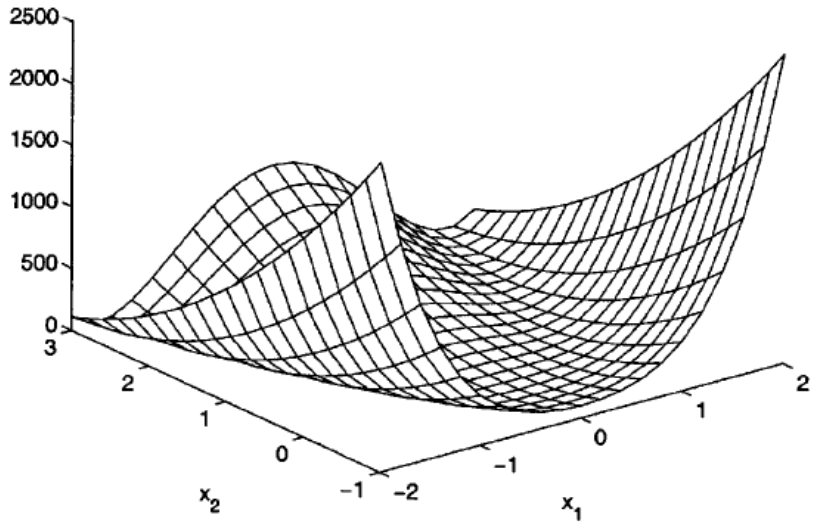

Figure 5.2 Graph of Rosenbrock's function

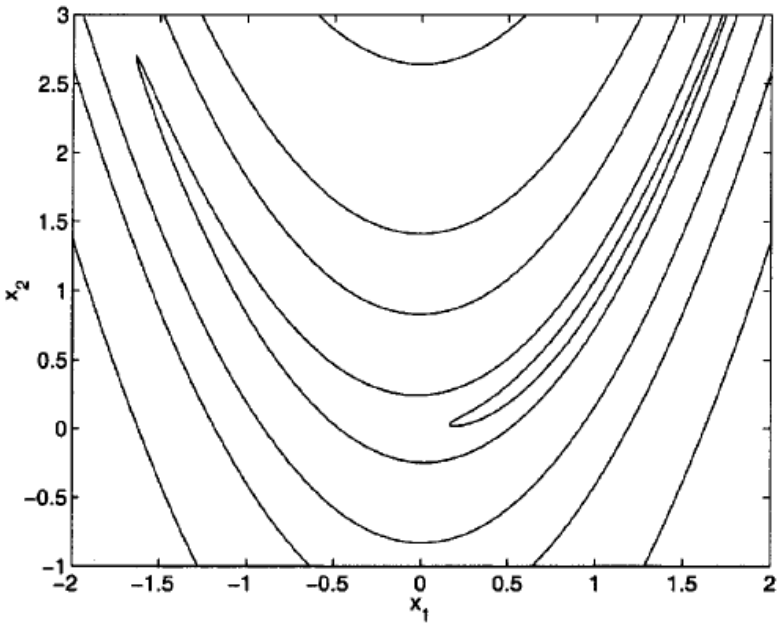

Figure 5.3 Level sets of Rosenbrock's (banana) function

试一试 画出一个球的水平集

水平集

通常情况下，水平集有以下性质：

1. 不同的水平集不相交。
2. 水平集稠密的地方，目标函数的变化较快，稀疏的地方，变化较慢。
3. 在极值点附近，水平集近似呈现为同心椭圆族。

梯度

- 梯度定义：如果$f:\mathbb{R}^n \to \mathbb{R}$是一阶可微的，那么函数

$$\nabla f(\boldsymbol{x}) = \begin{bmatrix} \frac{\partial f(\boldsymbol{x})}{\partial x_1} \\ \vdots \\ \frac{\partial f(\boldsymbol{x})}{\partial x_n} \end{bmatrix} = Df(\boldsymbol{x})^T$$

称为f的梯度。∇可读做“纳布拉”，即$nabla$的发音。
$\nabla f(\boldsymbol{x})$以$f(x)$每个偏导数作为分量的一个列向量。

- 常见的高维函数梯度：

1. 常数向量$\boldsymbol{c} \in \mathbb{R}^n, \nabla \boldsymbol{c} = 0$
2. $\boldsymbol{c}, \boldsymbol{x} \in \mathbb{R}^n, \nabla(\boldsymbol{c}^T\boldsymbol{x}) = \boldsymbol{c}$
3. $\boldsymbol{x} \in \mathbb{R}^n, \nabla(\boldsymbol{x}^T\boldsymbol{x}) = 2\boldsymbol{x}$
4. 若A是n阶对称矩阵，则$\nabla(\boldsymbol{x}^T\boldsymbol{A}\boldsymbol{x}) = 2\boldsymbol{A}\boldsymbol{x}$
5. 若A是n阶对称矩阵，$f(\boldsymbol{x}) = \frac{1}{2}\boldsymbol{x}^T\boldsymbol{A}\boldsymbol{x} + \boldsymbol{b}^T\boldsymbol{x} + c, \nabla f(\boldsymbol{x}) = \boldsymbol{A}\boldsymbol{x} + \boldsymbol{b}$

请证明(4)？（展开$\boldsymbol{x}^T\boldsymbol{A}\boldsymbol{x}$,针对每个$x_i$求偏导数）

梯度

- 证明1：若$\boldsymbol{A}$是n阶对称矩阵，$f(\boldsymbol{x}) = \boldsymbol{x}^T\boldsymbol{x}$，证明$\nabla f(\boldsymbol{x}) = 2\boldsymbol{x}$

- 证明2：若$\boldsymbol{A}$是n阶对称矩阵，$f(\boldsymbol{x}) = \boldsymbol{x}^T\boldsymbol{A}\boldsymbol{x}$，证明$\nabla(\boldsymbol{x}^T\boldsymbol{A}\boldsymbol{x}) = 2\boldsymbol{A}\boldsymbol{x}$

梯度

- 性质1：对于任意一条经过$\boldsymbol{x}_0$水平集$f(\boldsymbol{x}) = f(\boldsymbol{x}_0)$，其在点$\boldsymbol{x}_0$的切向量与函数$f$在点$\boldsymbol{x}_0$的梯度$\nabla f(\boldsymbol{x})$正交。即$\nabla f(\boldsymbol{x})$与$\boldsymbol{x}_0$处水平集垂直

- 性质2：沿梯度方向的函数具有最大变化率（增长率）

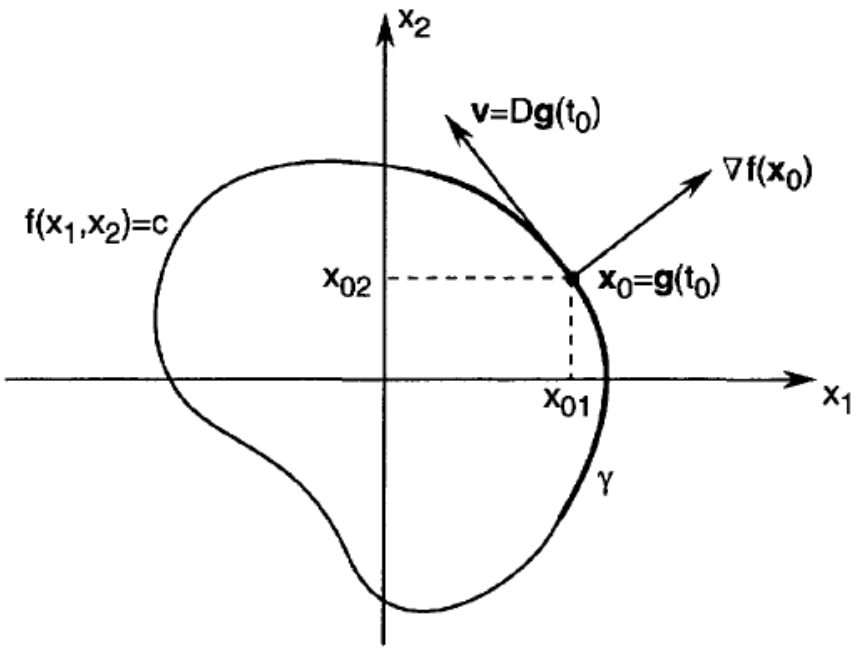

Figure 5.4 Orthogonality of the gradient to the level set

黑塞矩阵

梯度对应的是$f(\boldsymbol{x})$的一阶导数，那么二阶导数是什么呢?

- 黑塞矩阵

如果$f:\mathbb{R}^n \to \mathbb{R}$是二阶可微的，$\nabla f(\boldsymbol{x})$的导数可记为

$$\nabla^2 f(\boldsymbol{x}) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_2 \partial x_1} & \cdots & \frac{\partial^2 f}{\partial x_n \partial x_1} \\ \frac{\partial f}{\partial x_1 \partial x_2} & \frac{\partial f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_n \partial x_2} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_1 \partial x_n} & \frac{\partial^2 f}{\partial x_2 \partial x_n} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix}$$

其中$\frac{\partial^2 f}{\partial x_i \partial x_j}$表示$f$首先对$x_j$然后再对$x_i$求导。

矩阵$\nabla^2 f(\boldsymbol{x})$称为$f$在点$x$处的黑塞矩阵。（教材中常记为$F(\boldsymbol{x})$，或$D^2 f(\boldsymbol{x})$）

雅可比矩阵

- 雅可比矩阵(Jacobian Matrix)

如果$f:\mathbb{R}^n \to \mathbb{R}^{\mathrm{m}}$是定义在$D$上的n维函数$\boldsymbol{f}(\boldsymbol{x}) = \begin{bmatrix} f_1(\boldsymbol{x}) \\ \vdots \\ f_m(\mathbf{x}) \end{bmatrix}$且$f_1(\boldsymbol{x}), \dots, f_m(\boldsymbol{x})$可微，那么

$$\mathrm{D}\boldsymbol{f}(\boldsymbol{x}) = \begin{bmatrix} \frac{\partial f_1(\boldsymbol{x})}{\partial x_1} & \frac{\partial f_1(\boldsymbol{x})}{\partial x_2} & \cdots & \frac{\partial f_1(\boldsymbol{x})}{\partial x_n} \\ \frac{\partial f_2(\boldsymbol{x})}{\partial x_1} & \frac{\partial f_2(\boldsymbol{x})}{\partial x_2} & \cdots & \frac{\partial f_2(\boldsymbol{x})}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_m(\boldsymbol{x})}{\partial x_1} & \frac{\partial f_m(\boldsymbol{x})}{\partial x_2} & \cdots & \frac{\partial f_m(\boldsymbol{x})}{\partial x_n} \end{bmatrix}$$

称为 $\boldsymbol{f}(\boldsymbol{x})$在$\boldsymbol{x}$的导数，也称为 $\boldsymbol{f}(\boldsymbol{x})$在$\boldsymbol{x}$的雅可比矩阵。

注意区分黑塞矩阵和雅克比矩阵（雅可比矩阵可看成一个$\mathbb{R}^n \to \mathbb{R}^{\mathrm{m}}$ 函数的一阶导数）

梯度和黑塞矩阵

- 试求以下函数的梯度和黑塞矩阵

$$f(\boldsymbol{x}) = x_1^4 + 2x_2^3 + 3x_3^2 - x_1^2 x_2 + 4x_2 x_3 - x_1 x_3^2$$

解:

$$\nabla f(x) =$$

$$[4x_1^3 - 2x_1 x_2 - x_3^2, \quad -x_1^2 + 6x_2^2 + 4x_3, \quad -2x_1 x_3 + 4x_2 + 6x_3]^T$$

$$\nabla^2 f(x) = \begin{bmatrix} 12x^2 - 2x_2 & -2x_1 & -2x_3 \\ -2x_1 & 12x_2 & 4 \\ -2x_3 & 4 & -2x_1 + 6 \end{bmatrix}$$

梯度和黑塞矩阵

- 设$f(\boldsymbol{x})$在定义域内二阶可微，$\phi(\alpha)=f(\boldsymbol{x}+\alpha\boldsymbol{p})$，分别求$\phi(\alpha)$的一阶二阶导数$\phi'(\alpha)$，$\phi''(\alpha)$。

解：设$\boldsymbol{x},\boldsymbol{p}\in\mathbb{R}^n$， $\phi(\alpha)=f(x_1+\alpha p_1,\dots,x_n+\alpha p_n)$

令$y_i=x_i+\alpha p_i\Rightarrow\phi(\alpha)=f(y_1,\dots,y_n)=f(\boldsymbol{y})$

由多元复合函数的求导公式，

$$\phi'(\alpha)=\sum_{i=1}^{n}\frac{\partial f(\boldsymbol{y})}{\partial y_i}p_i=\nabla f(\boldsymbol{y})^T\boldsymbol{p}=\nabla f(\boldsymbol{x}+\alpha\boldsymbol{p})^T\boldsymbol{p}$$

$$\phi''(\alpha)=\sum_{i=1}^{n}\frac{d}{d\alpha}\left(\frac{\partial f(\boldsymbol{y})}{\partial y_i}\right)p_i=\sum_{i=1}^{n}\left(\frac{d}{d\alpha}\left(\frac{\partial f(x_1+\alpha p_1,\dots,x_n+\alpha p_n)}{\partial y_i}\right)\right)p_i$$

$$=\sum_{i=1}^{n}\left(\sum_{j=1}^{n}\frac{\partial^2 f(\boldsymbol{y})}{\partial y_j\partial y_i}p_j\right)p_i=\boldsymbol{p}^T\nabla^2 f(\boldsymbol{x}+\alpha\boldsymbol{p})\boldsymbol{p}$$

二次型函数

- 二次型函数：

函数$f: \mathbb{R}^{\boldsymbol{n}} \to \mathbb{R}$如果可以表示为$f(\boldsymbol{x}) = \boldsymbol{x}^{\boldsymbol{T}}\boldsymbol{Q}\boldsymbol{x}$，被称为二次型函数，其中$\boldsymbol{Q}$是一个$n \times n$的实数矩阵。

对于$f(\boldsymbol{x}) = \boldsymbol{x}^{\boldsymbol{T}}\boldsymbol{Q}\boldsymbol{x}$，如果$\boldsymbol{Q}$是一个$n \times n$实数矩阵，我们可以将$\boldsymbol{Q}$转化为一个对称矩阵$\boldsymbol{Q_0}$，使得

$$\boldsymbol{Q_0} = \boldsymbol{Q_0^T} = \frac{1}{2}(\boldsymbol{Q} + \boldsymbol{Q^T})$$

显然$f(\boldsymbol{x}) = \boldsymbol{x}^{\boldsymbol{T}}\boldsymbol{Q}\boldsymbol{x} = \boldsymbol{x}^{\boldsymbol{T}}\boldsymbol{Q_0}\boldsymbol{x} = \boldsymbol{x}^{\boldsymbol{T}}(\frac{1}{2}\boldsymbol{Q} + \frac{1}{2}\boldsymbol{Q^T})\boldsymbol{x}$

因此，不失一般性，可以假定二次型函数Q是对称阵。

注：教材上要求$f(\boldsymbol{x}) = \boldsymbol{x}^{\boldsymbol{T}}\boldsymbol{Q}\boldsymbol{x}$的形式，但更一般的说，$f(\boldsymbol{x}) = \boldsymbol{x}^T\boldsymbol{Q}\boldsymbol{x} + \boldsymbol{b}^{\boldsymbol{T}}\boldsymbol{x} + c$也被称为二次型函数

二次型函数

将$f(\boldsymbol{x}) = 5x_1^2 + 3x_2^2 + 2x_3^2 - x_1x_2 + 8x_2x_3$写成$\boldsymbol{x}^T\boldsymbol{Q}\boldsymbol{x}$的形式，要求$\boldsymbol{Q}$是对称矩阵。

解:

$$\boldsymbol{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}, Q = \begin{bmatrix} 5 & -\frac{1}{2} & 0 \\ -\frac{1}{2} & 3 & 4 \\ 0 & 4 & 2 \end{bmatrix}$$

二次型函数

- 正定矩阵

给出对称矩阵$\boldsymbol{Q} \in \mathbb{R}^{n\times n}$,如果对于任意一个非零向量$\boldsymbol{x} \in \mathbb{R}^{n}$满足：

$$\boldsymbol{x}^{\boldsymbol{T}}\boldsymbol{Q}\boldsymbol{x} > 0$$

则$\boldsymbol{Q}$是一个正定矩阵。如果$\boldsymbol{x}^{T}\boldsymbol{Q}\boldsymbol{x} \geq 0$，则$\boldsymbol{Q}$是一个半正定矩阵。相应的，如果对于所有的$\boldsymbol{x} \in \mathbb{R}^{n}$，$\boldsymbol{x}^{\boldsymbol{T}}\boldsymbol{Q}\boldsymbol{x} < 0$（$\boldsymbol{x}^{\boldsymbol{T}}\boldsymbol{Q}\boldsymbol{x} \leq 0$），$\boldsymbol{Q}$是负定矩阵（半负定矩阵）

性质1：对称矩阵$\boldsymbol{Q}$是正定的当且仅当$\boldsymbol{Q}$的所有顺序主子式是正的。

性质2：对称矩阵$\boldsymbol{Q}$是正定（半正定）矩阵当且仅当所有的特征值都是正的（非负的）。

注意：顺序主子式非负是对称半正定矩阵的必要条件，非充分条件。

高维泰勒展开

- 高维函数一阶泰勒展开式

设$f: \mathrm{D} \subset \mathbb{R}^n \to \mathbb{R}$，若$f(\boldsymbol{x})$在$\boldsymbol{x^0}$某邻域$N(\boldsymbol{x^0}, \delta) \subset \boldsymbol{D}$（$\boldsymbol{x^0}$是$D$的内点）内一阶连续可微，对任意的$\boldsymbol{x} \in N(\boldsymbol{x^0}, \delta)$,有：

$$f(\boldsymbol{x}) = f(\boldsymbol{x}^0) + \nabla f(\boldsymbol{x^0})^T (\boldsymbol{x} - \boldsymbol{x}^0) + o(\|\boldsymbol{x} - \boldsymbol{x}^0\|)$$

- 高维函数二阶泰勒展开式

设$f: D \subset \mathbb{R}^n \to \mathbb{R}$，若$f(\boldsymbol{x})$在$\boldsymbol{x^0}$某邻域$N(\boldsymbol{x^0}, \delta) \subset D$内二阶连续可微，对任意的$\boldsymbol{x} \in N(\boldsymbol{x^0}, \delta)$，有：

$$f(\boldsymbol{x}) = f(\boldsymbol{x}^0) + \nabla f(\boldsymbol{x^0})^T (\boldsymbol{x} - \boldsymbol{x}^0) + \frac{1}{2}(\boldsymbol{x} - \boldsymbol{x}^0)^{\mathrm{T}} \nabla^2 f(\boldsymbol{x}^0)(\boldsymbol{x} - \boldsymbol{x^0}) + o(\|\boldsymbol{x} - \boldsymbol{x}^0\|^2)$$

集合约束优化

让f：$\mathbb{R}^n \to \mathbb{R}$，$x \in \Omega \subseteq \mathbb{R}$.

我们考虑有集合约束的优化问题：

$$\begin{aligned} &minimize\ f(x) \\ &subject\ to\ \ x \in \Omega \end{aligned}$$

可行方向

- 已知向量$\boldsymbol{d} \in \mathbb{R}^n$（$\boldsymbol{d} \neq 0$）和约束集中的某个点$\boldsymbol{x} \in \Omega$，如果存在一个实数$\alpha_0 > 0$,使得对于所有的$\alpha \in [0, \alpha_0]$,$\boldsymbol{x} + \alpha \boldsymbol{d}$仍然在约束集内部，即$\boldsymbol{x} + \alpha \boldsymbol{d} \in \Omega$,则$\boldsymbol{d}$称为$\boldsymbol{x}$处的**可行方向**。

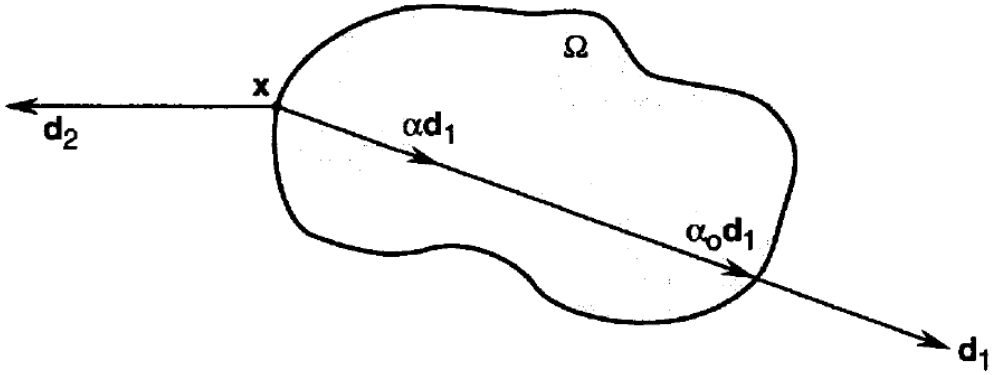

Figure 6.2 Two-dimensional illustration of feasible directions; $\boldsymbol{d}_1$ is a feasible direction, $\boldsymbol{d}_2$ is not a feasible direction

对于一个约束集的内点$x \in \mathbb{R}^n$，任意$d \in \mathbb{R}^n$都是可行方向

方向导数

设$\boldsymbol{d} \in \mathbb{R}^n$,可微函数$f(\boldsymbol{x})$在$\boldsymbol{x}$点沿方向$\boldsymbol{d}$的方向导数定义为:

$$\begin{aligned}\frac{\partial f}{\partial \boldsymbol{d}}(\boldsymbol{x}) &= \frac{df(\boldsymbol{x}+\alpha\boldsymbol{d})}{d\alpha} \\ &= \lim_{\alpha\to 0^+}\frac{f(\boldsymbol{x}+\alpha\boldsymbol{d})-f(\boldsymbol{x})}{\alpha} \\ &= \lim_{\alpha\to 0^+}\frac{\alpha\nabla f(\boldsymbol{x})^{\boldsymbol{T}}\boldsymbol{d}+o(\alpha)}{\alpha} \\ &= \lim_{\alpha\to 0^+}\left[\nabla f(\boldsymbol{x})^T\boldsymbol{d}+\frac{o(\alpha)}{\alpha}\right] \\ &= \nabla f(\boldsymbol{x})^T\boldsymbol{d}\end{aligned}$$

其中$(\nabla f(\boldsymbol{x}), \boldsymbol{d})$ 是向量$\nabla f(\boldsymbol{x})$和$\boldsymbol{d}$的夹角。

方向导数是多元微积分中的概念。如果$\|\boldsymbol{d}\| = \mathbf{1}$，方向导数就是$f(\boldsymbol{x})$沿着方向$\boldsymbol{d}$的增长量，即$\|\nabla f(\boldsymbol{x})\| cos(\nabla f(\boldsymbol{x}), \boldsymbol{d})$ 。

极值点定义

- 局部极小点：存在n维实值函数$f:\Omega\subset\mathbb{R}^n\to\mathbb{R}$,对于定义域$D$内的点$\boldsymbol{x}^*\in\Omega$，如果存在$\varepsilon>0$，对于所有满足$\boldsymbol{x}\in\Omega\backslash\{\boldsymbol{x}^*\}$ 且$\|\boldsymbol{x}-\boldsymbol{x}^*\|<\varepsilon$，使得 $f(\boldsymbol{x})\geq f(\boldsymbol{x}^*)$都成立，则$\boldsymbol{x}^*$是函数$f$在定义域$\Omega$中的一个局部极小点。

- 全局极小点：如果对于所有的$\boldsymbol{x}\in\Omega\backslash\{\boldsymbol{x}^*\}$，不等式$f(\boldsymbol{x})\geq f(\boldsymbol{x}^*)$都成立，那么$\boldsymbol{x}^*$是定义域$\Omega$上的一个全局极小点。

- 严格极小点：如果将定义中的≥换成>,那么定义对应严格局部极小点和严格全局极小点。

极值点定义

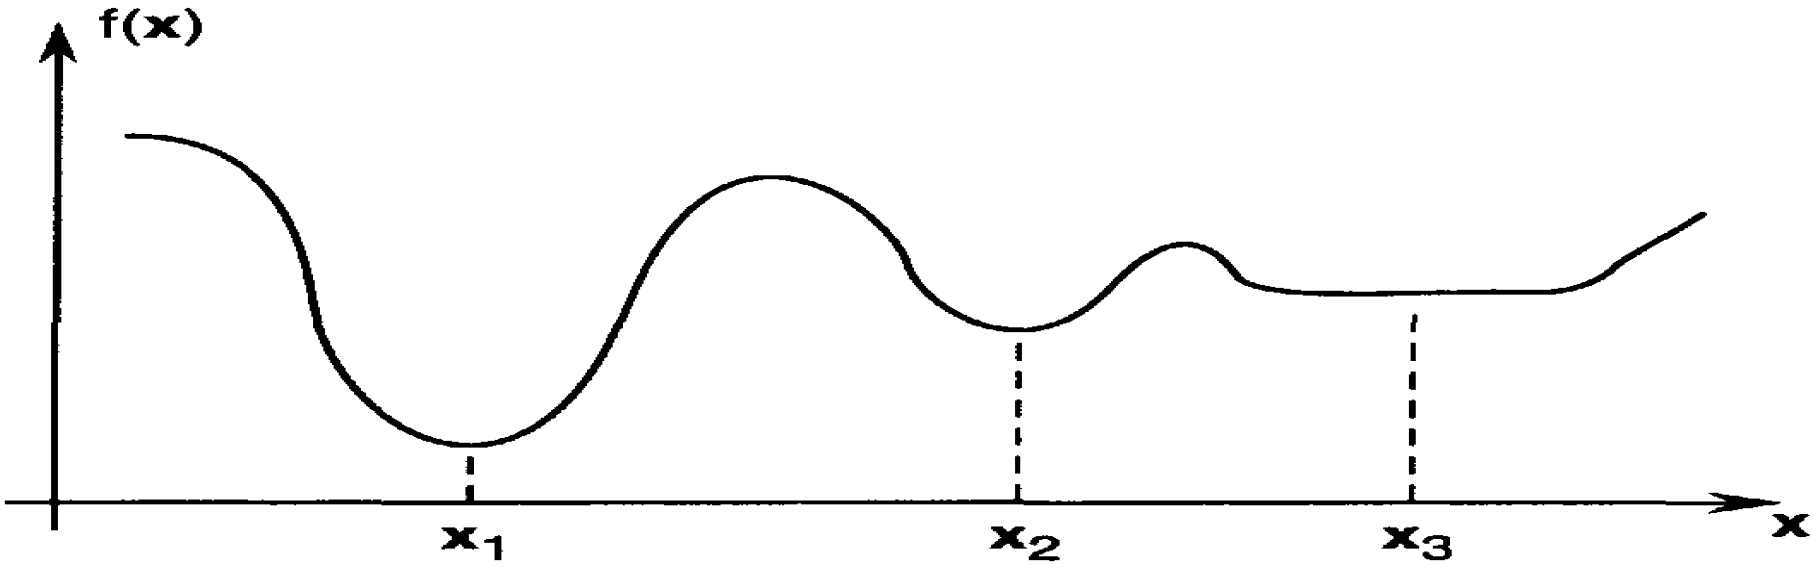

哪些是全局极小点？哪些是局部极小点？是否是严格的？

注意：在实际应用中，全局极小点经常是很难得到的，一般只需要找到局部最小点就可以了。
在线性规划以及最后的全局优化方法，我们会介绍一些通用的求解全局极小点的算法。

一阶必要条件

- 一阶必要条件：多元实值函数f在$\Omega \subset \mathbb{R}^n$上一阶连续可微，如果$\boldsymbol{x}^*$是函数$f$在$\Omega$上的局部极小点，则对于$\boldsymbol{x}^*$处的任意可行方向$\boldsymbol{d}$，都有：

$$\boldsymbol{d}^T \nabla f(\boldsymbol{x}^*) \geq 0$$

成立。

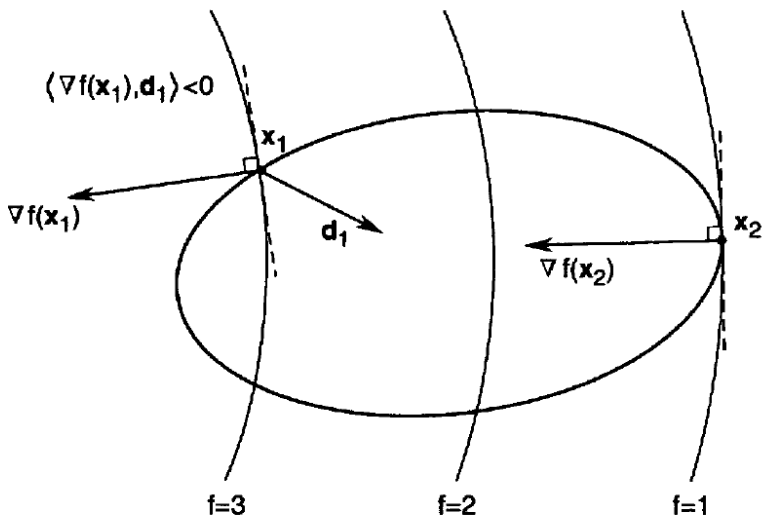

证明：设$\alpha > 0, \boldsymbol{x}^* + \alpha \boldsymbol{d} \in \Omega$。对于任一可行方向$\boldsymbol{d}$，定义$\phi(\alpha) = f(\boldsymbol{x}^* + \alpha \boldsymbol{d}), \phi(0) = f(\boldsymbol{x}^*)$。由泰勒定理(一阶麦克劳林公式)$f(\boldsymbol{x}^* + \alpha \boldsymbol{d}) - f(\boldsymbol{x}^*) = \phi(\alpha) - \phi(0) = \phi'(0)\alpha + o(\alpha) = \alpha \boldsymbol{d}^T \nabla f(\boldsymbol{x}^*) + o(\alpha)$。

由于$\boldsymbol{x}^*$是极小值，$f(\boldsymbol{x}^* + \alpha \boldsymbol{d}) \geq f(\boldsymbol{x}^*) \Rightarrow \alpha \boldsymbol{d}^T \nabla f(\boldsymbol{x}^*) + o(\alpha) \geq 0$。 $o(\alpha)$为高阶无穷小，因此当α足够小时，$\boldsymbol{d}^T \nabla f(\boldsymbol{x}^*) \geq 0$

一阶必要条件

- 局部极小点位于约束集内部的一阶必要条件:如果$\boldsymbol{x}^*$是$f(\boldsymbol{x})$在Ω内部的局部极小点，f在$\Omega \subset \mathbb{R}^n$上一阶连续可微$\Rightarrow \nabla f(\boldsymbol{x}^*) = 0$。

证明：由于$\boldsymbol{x}^*$是内点，那么任一方向都是可行方向。设$\boldsymbol{d}$是任取的一可行方向（$\|\boldsymbol{d}\| \neq 0$），由一阶必要条件得$\boldsymbol{d}^{\boldsymbol{T}} \nabla f(\boldsymbol{x}^*) \geq 0, -\boldsymbol{d}^{\mathrm{T}} \nabla f(\boldsymbol{x}^*) \geq 0 \Rightarrow \nabla f(\boldsymbol{x}^*) = 0$

- 注意：$\boldsymbol{x}^*$是Ω的内点，也可以说$\boldsymbol{x}^* \in \Omega$且$\Omega$是开集。

驻点：一阶导数为0的点。

极大值，极小值，鞍点都是驻点

二阶必要条件

- 二阶必要条件：多元实值函数f在约束集$\Omega \subset \mathbb{R}^n$上二阶连续可微。如果$\boldsymbol{x}^*$是函数$f$在$\Omega$上的局部极小点， $\boldsymbol{d}$是$\boldsymbol{x}^*$处的一个可行方向，且$\boldsymbol{d}^{\boldsymbol{T}}\nabla f(\boldsymbol{x}^*) = 0$，则有

$$\boldsymbol{d}^T\nabla^2\boldsymbol{f}(\boldsymbol{x}^*)\boldsymbol{d} \geq 0$$

成立。

证明：反证法。设局部极小点x^*满足$\boldsymbol{d}^{\boldsymbol{T}}\nabla f(\boldsymbol{x}^*) = 0$，$\boldsymbol{d}^T\nabla^2 f(\boldsymbol{x}^*)\boldsymbol{d} < 0$。设$\phi(\alpha) = f(\boldsymbol{x}^* + \alpha\boldsymbol{d})$。对$\phi(\alpha)$麦克劳林展开到二阶得$\phi(\alpha) - \phi(0) < 0$。产生矛盾。

- 局部极小点位于约束集内部二阶必要条件：如果$\boldsymbol{x}^*$是Ω内部的局部极小点，且$f(\boldsymbol{x})$在约束集Ω内二阶连续可微$\Rightarrow \nabla f(\boldsymbol{x}^*) = 0$ 且$\nabla^2 f(\boldsymbol{x}^*)$是半正定。

证明：由二阶必要条件可得。

二阶必要条件

- 注意上述条件均为必要条件

1. $f(x) = x^3 . f'(0) = 0, f''(0) = 0$但是0不是极小点（鞍点）
2. $f(x_1, x_2) = x_1^2 - x_2^2$，检测$x = [0,0]$的梯度和黑塞矩阵。

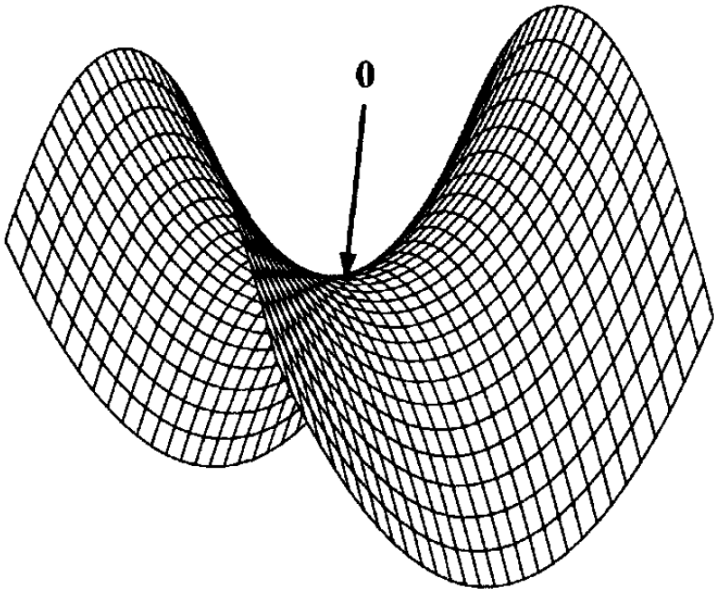

二阶充分条件

- 局部极小点的二阶充分条件*:如果$f(\boldsymbol{x})$在开集$\Omega \subset \mathbb{R}^n$内二阶连续可微，$\nabla f(\boldsymbol{x}^*) = 0$ 且$\nabla^2 f(\boldsymbol{x}^*)$正定$\Rightarrow$ $\boldsymbol{x}^*$是$f(\boldsymbol{x}^*)$在开集Ω内的一个严格极小点。

证明：泰勒展开,对于足够靠近$\boldsymbol{x}^*$的点$\boldsymbol{x}$:

$$f(\boldsymbol{x}) - f(\boldsymbol{x}^*) = \nabla f(\boldsymbol{x}^*)(\boldsymbol{x} - \boldsymbol{x}^*) + \frac{1}{2}(\boldsymbol{x} - \boldsymbol{x}^*)^T \nabla^2 f(\boldsymbol{x}^*)(\boldsymbol{x} - \boldsymbol{x}^*) + o(\|\boldsymbol{x} - \boldsymbol{x}^*\|^2)$$

$$= \frac{1}{2}(\boldsymbol{x} - \boldsymbol{x}^*)^T \nabla^2 f(\boldsymbol{x}^*)(\boldsymbol{x} - \boldsymbol{x}^*) + o(\|\boldsymbol{x} - \boldsymbol{x}^*\|^2)$$

由于瑞利不等式$\lambda_{min}\|\boldsymbol{x} - \boldsymbol{x}^*\|^2 \le (\boldsymbol{x} - \boldsymbol{x}^*)^T \nabla^2 f(\boldsymbol{x})(\boldsymbol{x} - \boldsymbol{x}^*) \le \lambda_{max}\|\boldsymbol{x} - \boldsymbol{x}^*\|^2$，因此$(\boldsymbol{x} - \boldsymbol{x}^*)^T \nabla^2 f(\boldsymbol{x}^*)(\boldsymbol{x} - \boldsymbol{x}^*)$是$\|\boldsymbol{x} - \boldsymbol{x}^*\|^2$的同阶无穷小。$f(\boldsymbol{x}) - f(\boldsymbol{x}^*)$的正负由第一项决定，而$\nabla^2 f(\boldsymbol{x}^*)(\boldsymbol{x} - \boldsymbol{x}^*)$正定$\Rightarrow$ $\lambda_{min} > 0$

因此对足够靠近点$\boldsymbol{x}^*$的点x

$$f(\boldsymbol{x}) - f(\boldsymbol{x}^*) > 0$$

$\boldsymbol{x}^*$是$f(\boldsymbol{x}^*)$在开集Ω内的一个严格极小点

小结

- 最优化的基础知识：

1.梯度，黑塞矩阵，二次型

2. 高维泰勒展开式（至少能展开到二阶），可行方向

3.局部极小值，全局极小值，严格极小值

- 最优化条件：

1. 一阶必要条件，局部极小点位于约束集内部的一阶必要条件
2. 二阶必要条件，局部极小点位于约束集内部的二阶必要条件
3. 二阶充分条件*

谢 谢
THANKS