电子科技大学
University of Electronic Science and Technology of China

第2章 无约束高维优化

牛顿法

牛顿法

假设$f(\boldsymbol{x})$定义域内二阶可微,要求找出$f(\boldsymbol{x})$的局部极小点。即

$$\min_{\boldsymbol{x} \in \mathbb{R}^n} f(\boldsymbol{x})$$

能否使用黑塞矩阵，构造类似一维优化的牛顿法呢?

牛顿法

- 设目标函数在$f:\mathbb{R}^n \to \mathbb{R}$二阶连续可微，将函数在$\boldsymbol{x}^{(k)}$处泰勒展开，

$$
\begin{aligned}
&f(\boldsymbol{x}) \\
&= f(\boldsymbol{x}^{(k)}) + (\boldsymbol{x}-\boldsymbol{x}^{(k)})^T \nabla f\left(\boldsymbol{x}^{(k)}\right) + \frac{1}{2}(\boldsymbol{x}-\boldsymbol{x}^{(k)})^T \nabla^2 f\left(\boldsymbol{x}^{(k)}\right)\left(\boldsymbol{x}-\boldsymbol{x}^{(k)}\right) \\
&+ o(\left\|\boldsymbol{x}-\boldsymbol{x}^{(k)}\right\|^2)
\end{aligned}
$$

为方便描述，令

$$
q(\boldsymbol{x}) = f(\boldsymbol{x}^{(k)}) + (\boldsymbol{x}-\boldsymbol{x}^{(k)})^T \nabla f\left(\boldsymbol{x}^{(k)}\right) + \frac{1}{2}(\boldsymbol{x}-\boldsymbol{x}^{(k)})^T \nabla^2 f\left(\boldsymbol{x}^{(k)}\right)\left(\boldsymbol{x}-\boldsymbol{x}^{(k)}\right)
$$

进一步，设$\boldsymbol{g}^{(k)} = \nabla f\left(\boldsymbol{x}^{(k)}\right)$，$F\left(\boldsymbol{x}^{(k)}\right) = \nabla^2 f(\boldsymbol{x}^{(k)})$。

- 牛顿法的思想：利用$q(\boldsymbol{x})$在$\boldsymbol{x}^{(k)}$近似$f(\boldsymbol{x})$，即$q(\boldsymbol{x}) \approx f(\boldsymbol{x})$，然后找$q(\boldsymbol{x})$的极小点。$q(\boldsymbol{x})$极小点满足一阶必要条件:

$$
\nabla q(\boldsymbol{x}) = \boldsymbol{g}^{(k)} + \boldsymbol{F}\left(\boldsymbol{x}^{(k)}\right)\left(\boldsymbol{x}-\boldsymbol{x}^{(k)}\right) = \boldsymbol{0}
$$

如果$F\left(\boldsymbol{x}^{(k)}\right) > 0$，$q(\boldsymbol{x})$极小点为$\boldsymbol{x}^{(k)} - \boldsymbol{F}(\boldsymbol{x}^{(k)})^{-1}\boldsymbol{g}^{(k)}$

- 可得牛顿法迭代公式

$$
\boldsymbol{x}^{(k+1)} = \boldsymbol{x}^{(k)} - \boldsymbol{F}(\boldsymbol{x}^{(k)})^{-1}\boldsymbol{g}^{(k)}
$$

牛顿法

- 我们可以得到一个初步的牛顿法：

1. 初始化：选定初始点$\boldsymbol{x}^{(k)}, k=0$。
2. 通过$\boldsymbol{F}\left(\boldsymbol{x}^{(k)}\right)\boldsymbol{d}^{(k)}=-\boldsymbol{g}^{(k)}$计算$\boldsymbol{d}^{(k)}$。
3. 确定下一个迭代点$\boldsymbol{x}^{(k+1)}=\boldsymbol{x}^{(k)}+\boldsymbol{d}^{(k)}$。
4. 判断$\boldsymbol{x}^{(k+1)}$是否满足停机规则，如果满足，返回算法结果$\boldsymbol{x}^{(k+1)}$。否则，置$k=k+1$,回到第2步。

- 注意：由于解方程有标准的程序，$\boldsymbol{d}^{(k)}$是通过解方程$\boldsymbol{F}\left(\boldsymbol{x}^{(k)}\right)\boldsymbol{d}^{(k)}=-\boldsymbol{g}^{(k)}$得到的。

牛顿法

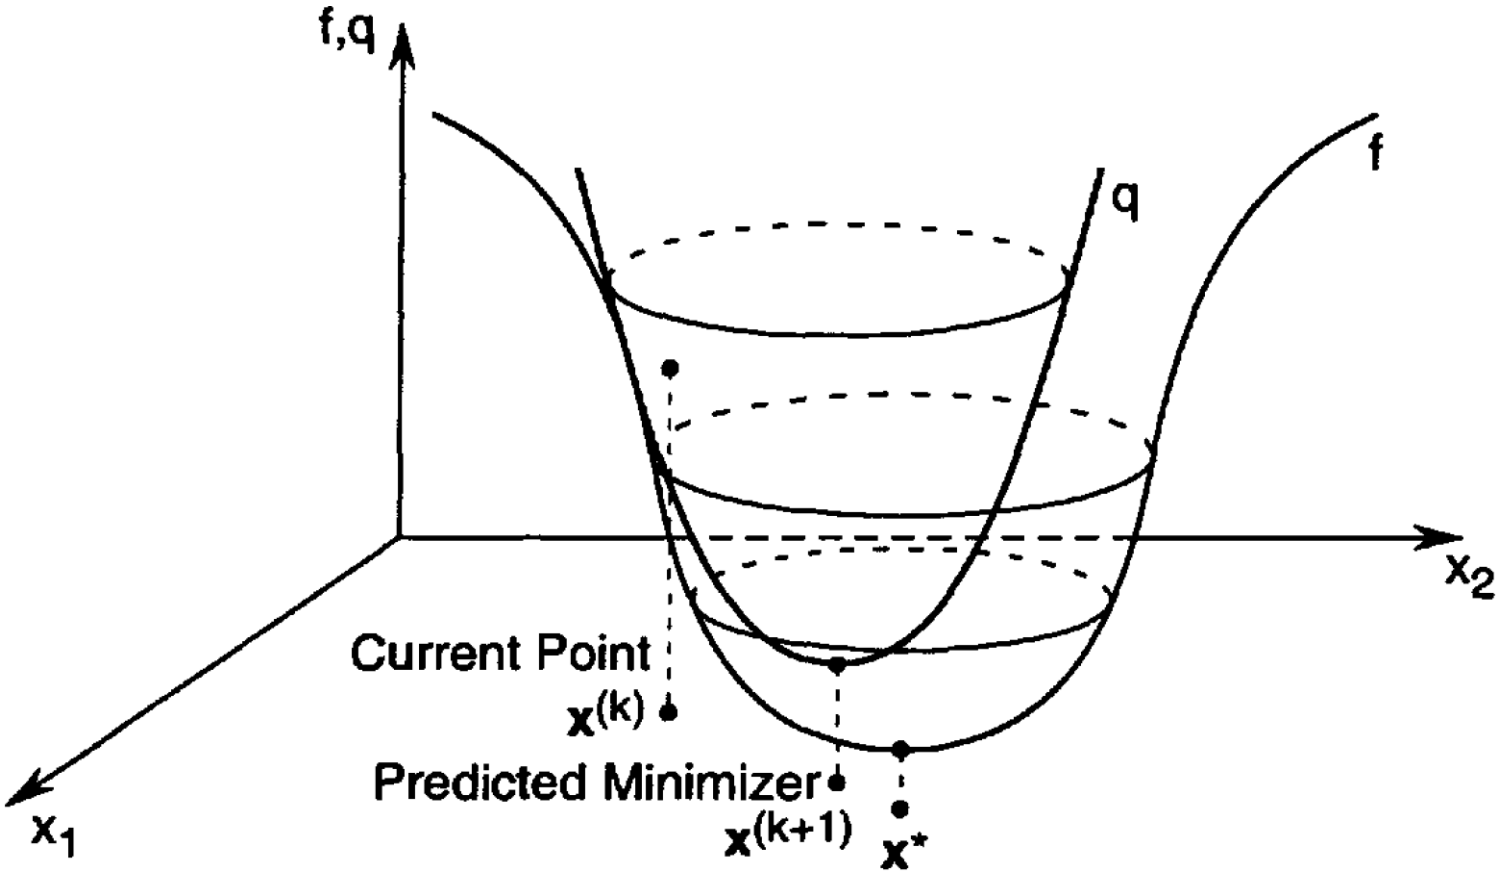

牛顿法

求解$f(\boldsymbol{x}) = f(x_1, x_2) = (x_1 - 2)^4 + (x_1 - 2x_2)^2$的极小点，设初始解为$\boldsymbol{x}^{(0)} = (x_1, x_2)^T = (0,3)^T$

解：

- $(k = 0)$: $f(\boldsymbol{x}^{(0)}) = 52$，$\boldsymbol{g}^{(0)} = \nabla f(x^{(0)}) = (-44,24)^T$，$\boldsymbol{F}(\boldsymbol{x}^{(0)}) = \begin{bmatrix} 50 & -4 \\ -4 & 8 \end{bmatrix}$

解$\boldsymbol{F}(\boldsymbol{x}^{(0)})\boldsymbol{d}^{(0)} = -\boldsymbol{g}^{(0)}$ 得$\boldsymbol{d}^{(0)} = -\boldsymbol{F}(\boldsymbol{x}^{(0)})^{-1}\boldsymbol{g}^{(0)} = (0.67, -2.67)^T$ （$\boldsymbol{F}(x^{(0)})^{-1} = \frac{1}{384}\begin{bmatrix} 8 & 4 \\ 4 & 50 \end{bmatrix}$）

- $k = 1$: $\boldsymbol{x}^{(1)} = \boldsymbol{x}^{(0)} + \boldsymbol{d}^{(0)} = (0.67,0.33)^T, f(\boldsymbol{x}^{(1)}) = 3.13$。

第一次迭代后，函数值确实下降了，按照同样的过程，只要不满足终止条件我们就可以一直迭代下去，下面给出前六次迭代的结果

表 4.1　计算结果

k	1	2	3	4	5	6	7
$\boldsymbol{X}^k$	$\begin{pmatrix} 0.00 \\ 3.00 \end{pmatrix}$	$\begin{pmatrix} 0.67 \\ 0.33 \end{pmatrix}$	$\begin{pmatrix} 1.11 \\ 0.56 \end{pmatrix}$	$\begin{pmatrix} 1.41 \\ 0.70 \end{pmatrix}$	$\begin{pmatrix} 1.61 \\ 0.80 \end{pmatrix}$	$\begin{pmatrix} 1.74 \\ 0.87 \end{pmatrix}$	$\begin{pmatrix} 1.83 \\ 0.91 \end{pmatrix}$
$f(\boldsymbol{X}^k)$	52	3.13	0.63	0.12	0.02	0.005	0.0009

如果我们要求函数$\left|f(x^{(k)}) - f(\boldsymbol{x}^{(k-1)})\right| \le 0.001$停机，则第7次迭代牛顿法停止，最优结果为$(1.83, 0.91)^T$.
实际上真正的最优解是$(2,1)^{\mathrm{T}}$，和上述解的区别主要源于精度误差。

牛顿法

注意牛顿法需要:

1. 计算$\boldsymbol{F}\left(\boldsymbol{x}^{(k)}\right)\boldsymbol{d}^{(k)} = -\boldsymbol{g}^{(k)}$需要求解一个n维的非齐次方程组。
2. 牛顿法也可以用于求解**多元方程组**$\boldsymbol{g}\ (\boldsymbol{x}) = \mathbf{0}$。其中$\boldsymbol{x} \in \mathbb{R}^n$, $\boldsymbol{g}: \mathbb{R}^n \to \mathbb{R}^n$。此时，$\boldsymbol{F}(\boldsymbol{x})$表示的是函数$\boldsymbol{g}$在$\boldsymbol{x}$处的雅克比矩阵，矩阵$\boldsymbol{F}(\boldsymbol{x}) \in \mathbb{R}^{n\times n}$的，第$(i,j)$个元素为$\left(\frac{\partial g_i}{\partial x_j}\right)(\boldsymbol{x})$。

牛顿法求解二次型

求正定二次型函数$f(\boldsymbol{x}) = \frac{1}{2}\boldsymbol{x}^T\boldsymbol{Q}\boldsymbol{x} - \boldsymbol{x}^T\boldsymbol{b}$的极小值，其中$\boldsymbol{Q} = \boldsymbol{Q}^T > \boldsymbol{0}$。

$\frac{1}{3}$

解：梯度和黑塞矩阵分别是

$$\boldsymbol{g}(\boldsymbol{x}) = \nabla f(\boldsymbol{x}) = \boldsymbol{Q}\boldsymbol{x} - \boldsymbol{b}$$

$$\boldsymbol{F}(\boldsymbol{x}) = \nabla^2 f(\boldsymbol{x}) = \boldsymbol{Q}$$

利用牛顿法迭代公式，可得在任意的初始点$\boldsymbol{x}^{\boldsymbol{0}}$下

$$\begin{aligned}\boldsymbol{x}^{(1)} &= \boldsymbol{x}^{(0)} - \boldsymbol{F}(\boldsymbol{x}^{(\boldsymbol{0})})^{-\boldsymbol{1}}\boldsymbol{g}^{(0)} \\ &= \boldsymbol{x}^{(0)} - \boldsymbol{Q}^{-1}[\boldsymbol{Q}\boldsymbol{x}^{(0)} - \boldsymbol{b}] \\ &= \boldsymbol{Q}^{-\boldsymbol{1}}\boldsymbol{b}\end{aligned}$$

实际上$f(\boldsymbol{x})$的最小值就是$\boldsymbol{Q}^{-\boldsymbol{1}}\boldsymbol{b}$，牛顿法可以仅需要一步就走到最小点。

牛顿法

- 当初始点离极小点较近时，牛顿迭代法所产生的序列不仅能收敛到极小点，而且收敛速度相当快；尤其当目标函数是正定二次型函数时，牛顿法能够一次达到极小点，其具有二阶收敛性。
- 定理：函数三阶连续可微，$\boldsymbol{x}^* \in \mathbb{R}^n$满足 $\nabla f(\boldsymbol{x}^*) = 0$，且$F(\boldsymbol{x}^*)$可逆。那么对于所有与$\boldsymbol{x}^*$足够接近的$\boldsymbol{x}^{(0)}$，牛顿法能够收敛，且至少以阶数为2的收敛率收敛到$\boldsymbol{x}^*$，即$0 < \lim\limits_{k\to\infty} \frac{\|\boldsymbol{x}^{(k+1)}-\boldsymbol{x}^*\|}{\|\boldsymbol{x}^{(k)}-\boldsymbol{x}^*\|^2} < \infty$。
- 但是，当初始点不理想时，牛顿法也会失败。

$\exists r>0$ $\|x^{(0)}-x^*\|<r$

定理成立

牛顿法

- 求解$\min f(x) = 4x_1^2 + x_2^2 - x_1^2 x_2$试分别取初始点$x^A = [1,1]^T$，$x^B = [3,4]^T$，$x^C = [2,0]^T$,精度$\varepsilon = 10^{-3}$，并用牛顿法求解。

解:

$$g(x) = \begin{bmatrix} 8x_1 - 2x_1x_2 \\ 2x_2 - x_1^2 \end{bmatrix} \quad F(\boldsymbol{x}) = \begin{bmatrix} 8 - 2x_2 & -2x_1 \\ -2x_1 & 2 \end{bmatrix}$$

1. $\boldsymbol{x}^{(1)} = \boldsymbol{x}^A$:

$g\left(\boldsymbol{x}^{(1)}\right) = (6,1)^T$，$||g\left(\boldsymbol{x}^{(1)}\right)|| = 6.0828 > \epsilon$，$F\left(\boldsymbol{x}^{(1)}\right) = \begin{pmatrix} 6 & -2 \\ -2 & 2 \end{pmatrix}$。

解方程组 $F\left(\boldsymbol{x}^{(1)}\right)\boldsymbol{d}^{(1)} = -g(\boldsymbol{x}^{(1)})$，得 $\boldsymbol{d}^{(1)} = (-1.7500, -2.2500)^T$，那么置 $\boldsymbol{x}^{(2)} = \boldsymbol{x}^{(1)} + \boldsymbol{d}^{(1)} = (0.7500, -1.2500)^T$

牛顿法

- 求解$\min f(x) = 4x_1^2 + x_2^2 - x_1^2 x_2$。试分别取初始点$\boldsymbol{x}^A = [1,1]^T$，$\boldsymbol{x}^B = [3,4]^T$，$\boldsymbol{x}^C = [2,0]^T$,精度$\varepsilon = 10^{-3}$，用牛顿法解。

1. $\boldsymbol{x}^A = [1,1]^T$的前五次迭代。

k	$\boldsymbol{x}^{(k)}$	$f(\boldsymbol{x}^{(k)})$	$g(\boldsymbol{x}^{(k)})$	$\lVert g(\boldsymbol{x}^{(k)})\rVert$	$\boldsymbol{F}(\boldsymbol{x}^{(k)})$
1	$\begin{pmatrix}1.0000\\1.0000\end{pmatrix}$	4.0000	$\begin{pmatrix}6.0000\\1.0000\end{pmatrix}$	6.0828	$\begin{pmatrix}6.0000 & -2.0000\\-2.0000 & 2.0000\end{pmatrix}$
2	$\begin{pmatrix}-0.7500\\-1.2500\end{pmatrix}$	4.5156	$\begin{pmatrix}-7.8750\\-3.0625\end{pmatrix}$	8.4495	$\begin{pmatrix}10.5000 & 1.5000\\1.5000 & 2.0000\end{pmatrix}$
3	$\begin{pmatrix}-0.1550\\-1.2500\end{pmatrix}$	0.1273	$\begin{pmatrix}-1.2912\\-0.3540\end{pmatrix}$	1.3388	$\begin{pmatrix}8.3300 & 0.3100\\0.3100 & 2.0000\end{pmatrix}$
4	$\begin{pmatrix}-0.0057\\-0.0111\end{pmatrix}$	0.0003	$\begin{pmatrix}-0.0459\\-0.0223\end{pmatrix}$	0.3298	$\begin{pmatrix}8.0223 & 0.0115\\0.0115 & 2.0000\end{pmatrix}$
5	$\begin{pmatrix}0.0000\\0.0000\end{pmatrix}$	0.0000	$\begin{pmatrix}0.0000\\0.0000\end{pmatrix}$	0.0000	

$\lVert g(\boldsymbol{x}^{(5)})\rVert = 0.0000 < \epsilon \Rightarrow \boldsymbol{x}^{(5)}$为极小值近似（真实极小值是$[0,0]^T$）

牛顿法

- 求解$\min f(x) = 4x_1^2 + x_2^2 - x_1^2 x_2$。试分别取初始点$\boldsymbol{x}^A = [1,1]^T$，$\boldsymbol{x}^B = [3,4]^T$，$\boldsymbol{x}^C = [2,0]^T$,精度$\varepsilon = 10^{-3}$，用牛顿法解。

2.取 $\boldsymbol{x}^{(1)} = \boldsymbol{x}^B$，迭代如下。

k	$\boldsymbol{x}^{(k)}$	$f(\boldsymbol{x}^{(k)})$	$g(\boldsymbol{x}^{(k)})$	$\|g(\boldsymbol{x}^{(k)})\|$	$\boldsymbol{F}(\boldsymbol{x}^{(k)})$
1	$\begin{pmatrix}3.0000\\4.0000\end{pmatrix}$	16.0000	$\begin{pmatrix}0.0000\\-1.0000\end{pmatrix}$	1.0000	$\begin{pmatrix}0.0000 & -6.0000\\-6.0000 & 2.0000\end{pmatrix}$
2	$\begin{pmatrix}2.8333\\4.0000\end{pmatrix}$	16.0000	$\begin{pmatrix}0.0000\\0.0278\end{pmatrix}$	0.1667	$\begin{pmatrix}0.0000 & -5.6667\\-5.6667 & 2.0000\end{pmatrix}$
3	$\begin{pmatrix}2.8284\\4.0000\end{pmatrix}$	16.0000	$\begin{pmatrix}0.0000\\0.0000\end{pmatrix}$	0.0000	

因 $\|g(\boldsymbol{x}^{(3)})\| = 0.0000 < \epsilon$，停止计算，这次迭代实际收敛到 $f(\boldsymbol{x})$ 的鞍点 $(2\sqrt{2}, 4)^T$

牛顿法

- 求解$\min f(x) = 4x_1^2 + x_2^2 - x_1^2 x_2$。试分别取初始点$\boldsymbol{x}^A = [1,1]^T$，$\boldsymbol{x}^B = [3,4]^T$，$\boldsymbol{x}^C = [2,0]^T$,精度$\varepsilon = 10^{-3}$，用牛顿法解。

3.取 $\boldsymbol{x}^{(1)} = \boldsymbol{x}^C$，计算可得

$$\boldsymbol{g}\left(\boldsymbol{x}^{(1)}\right) = \begin{pmatrix} 16 \\ -4 \end{pmatrix}, \boldsymbol{F}\left(\boldsymbol{x}^{(1)}\right) = \begin{pmatrix} 8 & -4 \\ -4 & 2 \end{pmatrix}$$

由 $\boldsymbol{F}\left(\boldsymbol{x}^{(1)}\right)$ 的行列式为0，可知方程 $F\left(\boldsymbol{x}^{(1)}\right)\boldsymbol{d}^{(1)} = -g(\boldsymbol{x}^{(1)})$ 无解，所以无法求得点 $\boldsymbol{x}^{(2)}$。

牛顿法缺点

❑ 缺点：

1. $F(\boldsymbol{x}^{(k)})$正定，由于目标函数复杂，不能保证移动 $f\left(\boldsymbol{x}^{(k+1)}\right) < f\left(\boldsymbol{x}^{(k)}\right)$。
   - 如上例中的第一种的情况；
2. 在$\boldsymbol{x}^{(k)}$处，$F(\boldsymbol{x}^{(k)})$矩阵非正定，$\boldsymbol{d}^{(k)}$非下降方向。
   - 如一维函数中出现$f''(x) < 0$的情况;
3. 在$\boldsymbol{x}^{(k)}$处，$F(\boldsymbol{x}^{(k)})$矩阵奇异，无法求解$F\left(\boldsymbol{x}^{(k)}\right)\boldsymbol{d}^{(k)} = -\boldsymbol{g}^{(k)}$。
   - 如上例中出现的第三种情况.

牛顿修正法（1）

- 修正问题1： $F(\boldsymbol{x}^{(k)})$正定，由于目标函数复杂，不能保证移动$f\left(\boldsymbol{x}^{(k+1)}\right) < f\left(\boldsymbol{x}^{(k)}\right)$;

首先，由$F\left(\boldsymbol{x}^{(k)}\right) > 0$(正定)，可证明 $\boldsymbol{d}^{(k)} = -\boldsymbol{F}(\boldsymbol{x}^{(k)})^{-1}\boldsymbol{g}^{(k)}$是一个下降方向。

- **定理：** $\{\boldsymbol{x}^{(k)}\}$是牛顿法求解目标函数$f(\boldsymbol{x})$极小点时得到的迭代序列，如果$F\left(\boldsymbol{x}^{(k)}\right) > 0$，且$\boldsymbol{g}^{(k)} = \nabla f(\boldsymbol{x}^{(k)}) \neq 0$，那么$\boldsymbol{d}^{(k)} = -\boldsymbol{F}(\boldsymbol{x}^{(k)})^{-1}\boldsymbol{g}^{(k)}$是一个下降方向。

即：存在$\bar{\alpha} > 0$，使得$\alpha \in (0, \bar{\alpha})$都有

$$f\left(\boldsymbol{x}^{(k)} + \alpha \boldsymbol{d}^{(k)}\right) < f\left(\boldsymbol{x}^{(k)}\right)$$

牛顿修正法（1）

- 如何解决$\boldsymbol{d}^{(k)}$是下降方向却出现$f\left(\boldsymbol{x}^{(k)}+\boldsymbol{d}^{(k)}\right)>f\left(\boldsymbol{x}^{(k)}\right)$的情况?

为方向$\boldsymbol{d}^{(k)}$设置步长!

- 具体来说，类似最速下降法，为下降方向$\boldsymbol{d}^{(k)}$设置一个步长α_k

$$\boldsymbol{x}^{(k+1)}=\boldsymbol{x}^{(k)}-\alpha_k F(\boldsymbol{x}^{(k)})^{-1}\boldsymbol{g}^{(k)}$$

步长的长度为目标函数的最大减小量,即

$$\alpha_k=\operatorname{argmin}_{\alpha>0} f(\boldsymbol{x}^{(k)}-\alpha F(\boldsymbol{x}^{(k)})^{-1}\boldsymbol{g}^{(k)})$$

由上定理$\boldsymbol{g}^{(k)}\neq 0$

$$f\left(\boldsymbol{x}^{(k+1)}\right)<f(\boldsymbol{x}^{(k)})$$

牛顿修正法（2）

- 修正问题2：$\boldsymbol{F}(\boldsymbol{x}^{(k)})$不正定,导致搜索方向不是下降方向。

我们采用**Levenberg-Marquardt**修正，迭代公式为：

$$\boldsymbol{x}^{(k+1)} = \boldsymbol{x}^{(k)} - (\boldsymbol{F}(\boldsymbol{x}^{(k)}) + \mu_k \boldsymbol{I})^{-1} g^{(k)}$$

其中$\mu_k \geq 0$，I是单位矩阵。该修正主要基于以下两条定理。

定理1：若 μ_k足够大，可以保证$\boldsymbol{F}(\boldsymbol{x}^{(k)}) + \mu_k \boldsymbol{I}$正定。

证明：设F特征值为$\lambda_1, \dots, \lambda_n$，特征向量$\boldsymbol{v}_1, \dots, \boldsymbol{v}_n$。$F$非正定，特征值可能为非正。考虑$\boldsymbol{G} = \boldsymbol{F} + \mu \boldsymbol{I}$，$\mu \geq 0$。则

$$\boldsymbol{G}\boldsymbol{v}_i = (\boldsymbol{F} + \mu \boldsymbol{I})\boldsymbol{v}_i = \boldsymbol{F}v_i + \mu \boldsymbol{I}\boldsymbol{v}_i = \lambda_i \boldsymbol{v}_i + \mu \boldsymbol{v}_i = (\lambda_i + \mu)\boldsymbol{v}_i$$

也就是说$\boldsymbol{v}_i$是$\boldsymbol{G}$的特征向量，对应特征值$\lambda_i + \mu$。只要μ保证$\forall\, i \leq n$，$\lambda_i + \mu > 0$，则$\boldsymbol{G}$的所有的特征值为正，即G正定。

牛顿修正法（2）

- **定理2**：如果$F(\boldsymbol{x}^{(k)})+\mu_k\boldsymbol{I}$正定，$-(F(\boldsymbol{x}^{(k)})+\mu_k\boldsymbol{I})^{-1}\boldsymbol{g}^{(k)}$也是一个下降方向.

证明：参考$-\boldsymbol{F}(\boldsymbol{x}^{(k)})^{-1}\boldsymbol{g}^{(k)}$是下降方向的证明

结合第一种修正方式，我们可以为**Levenberg-Marquardt**引入步长α_k，即$\boldsymbol{x}^{(k+1)}=\boldsymbol{x}^{(k)}-\alpha_k(F(\boldsymbol{x}^{(k)})+\mu_k\boldsymbol{I})^{-1}g^{(k)}$

- $\mu_k\to 0$时，Levenberg-Marquardt修正逐步接近牛顿法；$\mu_k\to\infty$时，Levenberg-Marquard表现出步长较小的梯度方法的特性。
- 实际中，可以先选择较小的μ_k，然后缓慢增加，直到出现下降特性，即$f\left(\boldsymbol{x}^{(k+1)}\right)<f(\boldsymbol{x}^{(k)})$

牛顿修正法（3）

- 修正问题：在$\boldsymbol{x}^{(k)}$处，$F(\boldsymbol{x}^{(k)})$矩阵奇异，无法求解$F\left(\boldsymbol{x}^{(k)}\right)\boldsymbol{d}^{(k)} = -\boldsymbol{g}^{(k)}$。

解决办法：在$\boldsymbol{x}^{(k)}$这一步换成最速梯度下降法

- 牛顿法还有一个运算上的缺点：黑塞矩阵的计算量较大。

解决办法：共轭法或则拟牛顿法

牛顿法在最小二乘的应用

- 我们考虑牛顿法的一个重要应用：最小二乘法求解。

$$\min_{x} \sum_{i=1}^{m} \left(r_i(\boldsymbol{x})\right)^2$$

其中$r_i: \mathbb{R}^n \to \mathbb{R}, i = 1, \dots, m$为给定的函数， 如果$r_i(\boldsymbol{x})$是线性函数，这类问题称为线性最小二乘问题（习题8.16就练习了固定步长梯度法求解线性最小二乘问题），反之，是非线性最小二乘问题。

$$\min_{x} \sum_{i=1}^{m} |r_i(x)|$$

牛顿法在最小二乘的应用

例：对于某一过程，在m个时刻开展m次测量，如图所示，

（其中m=21），令$t_1, \dots t_m$表示测量时刻，$y_1, \dots, y_m$表示测量值，其中，$t_1 = 0, t_{21} = 10$。要求构造正弦函数$y = Asin(\omega t + \phi)$拟合这些数据，参数为$A, \omega, \phi$。

t_1 t_2 . . . . .

y_2

y_1

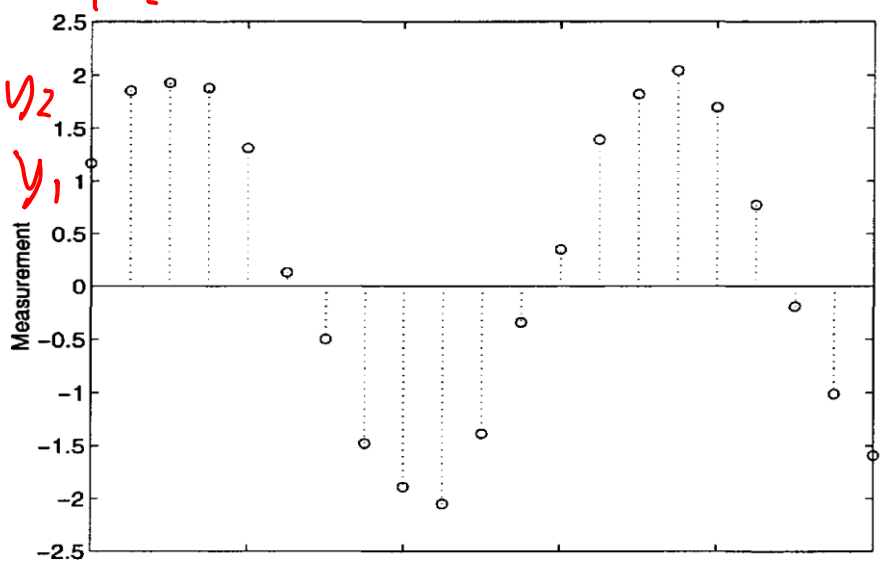

牛顿法在最小二乘的应用

求解的第一步是构造目标函数：

$$\sum_{i=1}^{m}\left(y_i - A\sin(\omega t_i + \phi)\right)^2$$

换成向量形式，令$\boldsymbol{x} = [A, \omega, \phi]^T$,$r_i(\boldsymbol{x}) = y_i - A\sin(\omega t_i + \phi)$。

$$\boldsymbol{r}(\boldsymbol{x}) = [r_1(\boldsymbol{x}), \dots, r_m(\boldsymbol{x})]^T$$

目标函数可以写成 $f(\boldsymbol{x}) = \boldsymbol{r}(\boldsymbol{x})^{\boldsymbol{T}}\boldsymbol{r}(\boldsymbol{x})$

牛顿法在最小二乘的应用

下面介绍牛顿法如何求解

$$\min f(\boldsymbol{x}) = \boldsymbol{r}(\boldsymbol{x})^{\boldsymbol{T}}\boldsymbol{r}(\boldsymbol{x})$$

解：先计算函数f的梯度和黑塞矩阵：

设$f(\boldsymbol{x}) = r_1(\boldsymbol{x})^2 + \cdots + r_m(\boldsymbol{x})^2$

那么$\left(\nabla f(\boldsymbol{x})\right)_j = \frac{\partial f(\boldsymbol{x})}{\partial x_j} = 2\sum_{i=1}^{m} r_i(\boldsymbol{x})\frac{\partial r_i(\boldsymbol{x})}{\partial x_j}$

回顾$\boldsymbol{r}(\boldsymbol{x})$的雅克比矩阵：

$$\boldsymbol{J}(\boldsymbol{x}) = \begin{bmatrix} \frac{\partial r_1}{\partial x_1}(x) & \cdots & \frac{\partial r_1}{\partial x_n}(x) \\ \vdots & \ddots & \vdots \\ \frac{\partial r_m}{\partial x_1}(x) & \cdots & \frac{\partial r_m}{\partial x_n}(x) \end{bmatrix}$$

$\nabla f(\boldsymbol{x})$可以表示为$\nabla f(\boldsymbol{x}) = 2\boldsymbol{J}(\boldsymbol{x})^{\boldsymbol{T}}\boldsymbol{r}(\boldsymbol{x})$

牛顿法在最小二乘的应用

- 继续牛顿法求解$\min f(\boldsymbol{x}) = \boldsymbol{r}(\boldsymbol{x})^T\boldsymbol{r}(\boldsymbol{x})$

下一步，我们需要知道$f(\boldsymbol{x})$的黑塞矩阵$\boldsymbol{F}(\boldsymbol{x})$：

第(k,j)个元素为

$$\frac{\partial^2 f}{\partial x_k \partial x_j}(\boldsymbol{x}) = \frac{\partial}{\partial x_k}\left(\frac{\partial f}{\partial x_j}(\boldsymbol{x})\right) = \frac{\partial}{\partial x_k}\left(2\sum_{i=1}^{m} r_i(\boldsymbol{x})\frac{\partial r_i}{\partial x_j}(\boldsymbol{x})\right)$$

$$= 2\sum_{i=1}^{m}\left(\frac{\partial r_i}{\partial x_k}(\boldsymbol{x})\frac{\partial r_i}{\partial x_j}(\boldsymbol{x}) + r_i(\boldsymbol{x})\frac{\partial^2 r_i}{\partial x_k \partial x_j}(\boldsymbol{x})\right)$$

因此，可以将黑塞矩阵写成

$$\boldsymbol{F}(\boldsymbol{x}) = 2(\boldsymbol{J}(\boldsymbol{x})^T\boldsymbol{J}(\boldsymbol{x}) + \boldsymbol{S}(\boldsymbol{x}))$$

其中$S(x)$的第(k,j)项是$\sum_{i=1}^{m} r_i(x)\frac{\partial^2 r_i}{\partial x_k \partial x_j}(x)$

这样就可以得到牛顿迭代法的应用到非线性二乘问题的迭代公式

$$\boldsymbol{x}^{(k+1)} = \boldsymbol{x}^{(k)} - (\boldsymbol{J}(\boldsymbol{x})^T\boldsymbol{J}(\boldsymbol{x}) + \boldsymbol{S}(\boldsymbol{x}))^{-1}\boldsymbol{J}(\boldsymbol{x})^T\boldsymbol{r}(\boldsymbol{x})$$

由于$S(x)$包含了r的二阶导数，很多元素都很小，所以经常被忽略。我们就得到了高斯牛顿法

$$\boldsymbol{x}^{(k+1)} = \boldsymbol{x}^{(k)} - (\boldsymbol{J}(\boldsymbol{x})^T\boldsymbol{J}(\boldsymbol{x}))^{-1}\boldsymbol{J}(\boldsymbol{x})^T\boldsymbol{r}(\boldsymbol{x})$$

小结

- 高维牛顿法是用二次型函数模拟某个点附近情况，模拟函数和原函数有相同的梯度和黑塞矩阵。
- 迭代公式$\boldsymbol{x}^{(k+1)} = \boldsymbol{x}^{(k)} - F(\boldsymbol{x}^{(k)})^{-1}\boldsymbol{g}^{(k)}$
- 针对失效情况的两种改进牛顿法

1. F正定，但是函数值不减小：引入步长

$$\boldsymbol{x}^{(k+1)} = \boldsymbol{x}^{(k)} - \alpha_k F(\boldsymbol{x}^{(k)})^{-1}\boldsymbol{g}^{(k)}$$

2. F不正定。改进：修改迭代公式为

$$\boldsymbol{x}^{(k+1)} = \boldsymbol{x}^{(k)} - (F(\boldsymbol{x}^{(k)}) + \mu_k \boldsymbol{I})^{-1} g^{(k)}$$

或$\boldsymbol{x}^{(k+1)} = \boldsymbol{x}^{(k)} - \alpha_k (F(\boldsymbol{x}^{(k)}) + \mu_k \boldsymbol{I})^{-1} g^{(k)}$

3. F奇异。改进：使用最速下降法走一步。

谢 谢
THANKS