电子科技大学
University of Electronic Science and Technology of China

第3-3章
约束问题的求解算法

2022/10/23

约束问题的求解算法

我们初步介绍约束优化问题的算法设计

$$min\, f(\boldsymbol{x})$$
$$s.t\ \boldsymbol{h}(\boldsymbol{x}) = 0$$
$$\boldsymbol{g}(\boldsymbol{x}) \leq 0$$

其中，$x \in \mathbb{R}^n$, $f: \mathbb{R}^n \to \mathbb{R}$, $\boldsymbol{h}: \mathbb{R}^n \to \mathbb{R}^m$, $\boldsymbol{g}: \mathbb{R}^n \to \mathbb{R}^p$, $m \leq n$。

算法：

- 投影法（线性约束）
- 外点法（或罚函数法，求解等式不等式约束优化问题）
- 内点法（或障碍函数法，求解不等式约束优化问题）

投影法

- 无约束优化算法大都有通用的迭代公式

$$\boldsymbol{x}^{(\boldsymbol{k}+\mathbf{1})} = \boldsymbol{x}^{(\boldsymbol{k})} + \alpha_k \boldsymbol{d}^{(k)}$$

$\boldsymbol{d}^k$是关于$\nabla f(\boldsymbol{x}^{(k)})$的函数，表示下一步的方向。

- 有约束优化问题也有类似的迭代投影算法。

投影法

- 投影法：考虑优化问题的约束集合为Ω，每一步检查新的点$\boldsymbol{x}^{(k)}+\alpha_k\boldsymbol{d}^{(k)}$是否在Ω内。如果在，继续迭代；如果不在，将$\boldsymbol{x}^{(k)}+\alpha_k\boldsymbol{d}^{(k)}$投影到Ω中后迭代。

为了投影到Ω内，定义一个投影算子$\boldsymbol{\Pi}(\boldsymbol{x})\in\mathbb{R}^n$。那么投影法迭代公式可表示为：

$$\boldsymbol{x}^{(k+1)}=\boldsymbol{\Pi}[\boldsymbol{x}^{(k)}+\alpha_k\boldsymbol{d}^{\langle k)}].$$

投影法

投影法一般将可行域Ω内“离$\boldsymbol{x}$最近的点”定义$\Pi[\boldsymbol{x}]$,即求

$$\Pi[\boldsymbol{x}] = \operatorname{argmin}_{\boldsymbol{z}\in\Omega}\|\boldsymbol{z}-\boldsymbol{x}\|$$

例:框式约束$\Omega = \{\boldsymbol{x}: l_i \le x_i \le u_i, i = 1, \dots, n\}$，Ω中离$\boldsymbol{x}$最近的点$\boldsymbol{z}$是

$$z_i = \begin{cases} u_i & if\ x_i > u_i \\ x_i & if\ l_i \le x_i \le u_i \\ l_i & if\ x_i < l_i \end{cases}$$

即，$\Pi[\boldsymbol{x}] = [z_1, \dots, z_n]^T$。

投影梯度法

考虑到负梯度是最速下降方向，我们可选择：

$$\boldsymbol{d}^{(\boldsymbol{k})} = -\nabla f(x^{(k)})$$

那么，投影法的迭代公式为

$$\boldsymbol{x}^{(k+1)} = \boldsymbol{\Pi}[\boldsymbol{x}^{(\boldsymbol{k})} - \alpha_k \nabla f(\boldsymbol{x}^{(k)})].$$

其中步长α_k有不同的实现方式，如固定步长，或最速下降步长

$$\alpha_k = argmin_{\alpha \geq 0} f(\boldsymbol{x}^{(\boldsymbol{k})} - \alpha \nabla f(\boldsymbol{x}^{(k)}))$$

投影梯度法

例：求解$\min \frac{1}{2}\boldsymbol{x}^{\boldsymbol{T}}\boldsymbol{Q}\boldsymbol{x}$，$s.t.\|\boldsymbol{x}\| = 1$。其中$\boldsymbol{Q} = \boldsymbol{Q}^T > 0$

(a). 利用拉格朗日乘子法求解该问题

(b). 已知$\boldsymbol{x} \neq \boldsymbol{0}$，推导出投影梯度法算法的更新方程，形如：$\boldsymbol{x}^{(\boldsymbol{k}+\boldsymbol{1})} = \boldsymbol{\Pi}[\boldsymbol{x}^{(\boldsymbol{k})} + \alpha\boldsymbol{d}^{(k)}]$,其中$\alpha$表示固定步长。

(c). 当$\boldsymbol{x}^{(\boldsymbol{0})}$是$\boldsymbol{Q}$的一个单位特征向量时，考察投影梯度法法收敛性。

解：（a）通过拉格朗日乘子法已知$\min \boldsymbol{x}^{\boldsymbol{T}}\boldsymbol{Q}\boldsymbol{x}$，$s.t.\boldsymbol{x}^{\boldsymbol{T}}\boldsymbol{P}\boldsymbol{x} = 1$的最优解是$\boldsymbol{P}^{-\boldsymbol{1}}\boldsymbol{Q}$的最小特征值对应的特征向量。

(b) 约束集是一个单位圆，任一个点$\boldsymbol{x}$到单位圆上最近距离的点就是$\boldsymbol{x}$同方向的单位向量，即$\boldsymbol{\Pi}[\boldsymbol{x}] = \frac{\boldsymbol{x}}{\|\boldsymbol{x}\|}$。由此可得更新方程为：$\boldsymbol{x}^{(\boldsymbol{k}+\boldsymbol{1})} = \boldsymbol{\Pi}\left[\boldsymbol{x}^{(\boldsymbol{k})} - \alpha\boldsymbol{Q}\boldsymbol{x}^{(\boldsymbol{k})}\right] = \frac{(\boldsymbol{I}-\alpha\boldsymbol{Q})\boldsymbol{x}^{(\boldsymbol{k})}}{\|(\boldsymbol{I}-\alpha\boldsymbol{Q})\boldsymbol{x}^{(\boldsymbol{k})}\|}$

(c) 如果$\boldsymbol{x}^{(\boldsymbol{0})}$是$\boldsymbol{Q}$的一个单位特征向量，对应的特征值是$\lambda$。则$(\boldsymbol{I} - \alpha\boldsymbol{Q})\boldsymbol{x}^{(\boldsymbol{0})} = \left(\boldsymbol{x}^{(\boldsymbol{0})} - \alpha\lambda\boldsymbol{x}^{(\boldsymbol{0})}\right) = (1 - \alpha\lambda)\boldsymbol{x}^{(\boldsymbol{0})}$。$\boldsymbol{x}^{(1)} = \frac{(1-\alpha\lambda)\boldsymbol{x}^{(\boldsymbol{0})}}{(1-\alpha\lambda)\|\boldsymbol{x}^{(0)}\|} = \boldsymbol{x}^{(\boldsymbol{0})}$。就是说$\boldsymbol{x}^{(\boldsymbol{k})}$恒等$\boldsymbol{x}^{\boldsymbol{0}}$，目标函数值为$\frac{\lambda}{2}$。当$\lambda$不是最小特征值时，显然不能收敛到最优解。

投影法

对于大多优化问题，找到投影点难度并不比原问题低。

例：考虑

$$\min \|\boldsymbol{x}\|^2 \ \ s.t. \boldsymbol{x} \in \boldsymbol{\Omega}.$$

该问题最优解为$\Pi[0]$。然而计算点0到$\boldsymbol{\Omega}$的投影值和原优化问题是一样的。

线性约束投影法

下面介绍投影法求解仅包含线性约束的问题

$$\min f(\boldsymbol{x})$$

$$\text{s.t.}\ \boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$$

其中$f: \mathbb{R}^n \to \mathbb{R}$，$\boldsymbol{A} \in \mathbb{R}^{m\times n}$, $m < n$, rank $\boldsymbol{A} = m$, $b \in \mathbb{R}^m$。

线性约束投影法

对问题$\min f(\boldsymbol{x})\ \text{s.t.}\ \boldsymbol{Ax}=\boldsymbol{b}$引入正交投影算子

$$\boldsymbol{P}=\boldsymbol{I}_n-\boldsymbol{A}^{\boldsymbol{T}}(\boldsymbol{AA}^{\boldsymbol{T}})^{-\boldsymbol{1}}\boldsymbol{A}$$

其中$\boldsymbol{I}_n$是$n\times n$的单位矩阵。

该投影算子有以下性质：

1. $\boldsymbol{P}=\boldsymbol{P}^{\boldsymbol{T}}$
2. $\boldsymbol{P}^{\boldsymbol{2}}=\boldsymbol{P}$
3. $\boldsymbol{x}^*$是一个可行点，$\boldsymbol{P}\nabla\boldsymbol{f}(\boldsymbol{x}^*)=\boldsymbol{0}$成立充要条件是$\boldsymbol{x}^*$满足拉格朗日条件。

证明（3）：充分：由拉格朗日条件$\nabla\boldsymbol{f}(\boldsymbol{x}^*)=-\boldsymbol{A}^{\boldsymbol{T}}\boldsymbol{\lambda}$

$\Rightarrow \boldsymbol{P}\nabla\boldsymbol{f}(\boldsymbol{x}^*)=(\boldsymbol{I}_n-\boldsymbol{A}^{\boldsymbol{T}}\left(\boldsymbol{AA}^{\boldsymbol{T}}\right)^{-\boldsymbol{1}}\boldsymbol{A})\nabla\boldsymbol{f}(\boldsymbol{x}^*)=(\boldsymbol{I}_n-\boldsymbol{A}^{\boldsymbol{T}}\left(\boldsymbol{AA}^{\boldsymbol{T}}\right)^{-\boldsymbol{1}}\boldsymbol{A})\left(-\boldsymbol{A}^{\boldsymbol{T}}\boldsymbol{\lambda}\right)$
$=\boldsymbol{A}^{\boldsymbol{T}}\boldsymbol{\lambda}-\boldsymbol{A}^{\boldsymbol{T}}\boldsymbol{\lambda}=\boldsymbol{0}$

必要：$(\boldsymbol{I}_n-\boldsymbol{A}^{\boldsymbol{T}}\left(\boldsymbol{AA}^{\boldsymbol{T}}\right)^{-\boldsymbol{1}}\boldsymbol{A})\nabla\boldsymbol{f}(\boldsymbol{x}^*)=\boldsymbol{0}\Rightarrow\nabla\boldsymbol{f}(\boldsymbol{x}^*)-\boldsymbol{A}^{\boldsymbol{T}}\left(\boldsymbol{AA}^{\boldsymbol{T}}\right)^{-\boldsymbol{1}}\boldsymbol{A})\nabla\boldsymbol{f}(\boldsymbol{x}^*)=\boldsymbol{0}$。令$\boldsymbol{\lambda}=-(\boldsymbol{AA}^{\boldsymbol{T}})^{-\boldsymbol{1}}\boldsymbol{A}\nabla\boldsymbol{f}(\boldsymbol{x}^*)$。则$\boldsymbol{\nabla f}(\boldsymbol{x}^*)+\boldsymbol{A}^{\boldsymbol{T}}\boldsymbol{\lambda}=\boldsymbol{0}$

线性约束投影法

那么投影法的迭代公式为

$$\Pi[\boldsymbol{x}^{(\boldsymbol{k})} - \alpha_k \nabla \boldsymbol{f}(\boldsymbol{x}^{(\boldsymbol{k})})] = \boldsymbol{x}^{(\boldsymbol{k})} - \alpha_k \boldsymbol{P} \nabla f(\boldsymbol{x}^{(k)})$$

- 投影迭代公式正确性：如果$\boldsymbol{x}^{(\boldsymbol{0})}$是可行的，那么每个$\boldsymbol{x}^{(k)}$就都是可行的；也就是说，对任意的$k \geq 0$,恒有$\boldsymbol{A}\boldsymbol{x}^{(k)} = \boldsymbol{b}$。

证明：如果$k = 0$时$\boldsymbol{A}\boldsymbol{x}^{(0)} = \boldsymbol{b}$，

$$\boldsymbol{A}\boldsymbol{x}^{(1)} = \boldsymbol{A}\left(\boldsymbol{x}^{(0)} - \alpha_k \boldsymbol{P} \nabla f\left(\boldsymbol{x}^{(0)}\right)\right)$$

$$= \boldsymbol{A}\boldsymbol{x}^{(0)} - \alpha_k \boldsymbol{A}\boldsymbol{P} \nabla f\left(\boldsymbol{x}^{(0)}\right)$$

$$= \boldsymbol{b} - \alpha_k \left(\boldsymbol{A} - \boldsymbol{A}\boldsymbol{A}^{\boldsymbol{T}}\left(\boldsymbol{A}\boldsymbol{A}^{\boldsymbol{T}}\right)^{-\boldsymbol{1}}\boldsymbol{A}\right) \nabla f\left(\boldsymbol{x}^{(0)}\right) = \boldsymbol{b}$$

以此类推$\mathrm{k} \geq 0, \boldsymbol{A}\boldsymbol{x}^{(k)} = \boldsymbol{b}$成立。

线性约束投影法

第二个问题$-\boldsymbol{P}\nabla f(\boldsymbol{x}^{(k)})$是否为下降方向呢?

- 投影法下降性质:$-\boldsymbol{P}\nabla f(\boldsymbol{x}^{(k)})$是$\boldsymbol{x}^{(k)}$处下降方向。

证明：只需要证明$\nabla f(\boldsymbol{x})^T\left(-\boldsymbol{P}\nabla f(\boldsymbol{x})\right) \leq 0$。

根据$\boldsymbol{P} = \boldsymbol{P}^2$，$\boldsymbol{P}$是一个半正定矩阵，因此上述不等式显然成立。

实际上，$-\boldsymbol{P}\nabla f(\boldsymbol{x}^{(k)})$是$\boldsymbol{x}^{(k)}$处下降速率最快的可行方向。

线性约束投影法

线性约束投影梯度法大致步骤如下：

（1）取一个初始点$x^{(0)}$满足$A\boldsymbol{x}^{(0)}=b$,置$k=0$

（2）第k次迭代，类似$\boldsymbol{x}^{(\boldsymbol{k}+\mathbf{1})}=\boldsymbol{x}^{(\boldsymbol{k})}-\alpha_k\boldsymbol{P}\boldsymbol{\nabla}f(\boldsymbol{x}^{(\boldsymbol{k})})$，$\alpha_k$通过求$\min f\left(\boldsymbol{x}^{(\boldsymbol{k})}-\alpha_k\boldsymbol{P}\nabla f\left(\boldsymbol{x}^{(\boldsymbol{k})}\right)\right)$获得。

（3）$k=k+1$。考虑$\boldsymbol{x}^{(k)}$是否满足停机条件。若满足，返回$\boldsymbol{x}^{(k)}$为最优解，否则返回第2步。

注意，理论上$\boldsymbol{P}\nabla\boldsymbol{f}\left(\boldsymbol{x}^{(\mathrm{k})}\right)=\mathbf{0}$是停机条件。但实际上可使用在前面讨论过的更实用的停机方式。

线性约束投影法

投影最速下降法具有收敛性质：

- 设$\{\boldsymbol{x}^{(k)}\}$是投影最速下降法产生的序列，如果 $\boldsymbol{P}\nabla \boldsymbol{f}\left(\boldsymbol{x}^{(\mathrm{k})}\right) \neq \mathbf{0}$,那么$\boldsymbol{f}\left(\boldsymbol{x}^{(k+1)}\right) < \boldsymbol{f}\left(\boldsymbol{x}^{(k)}\right)$

由于$-\boldsymbol{P}\nabla f(\boldsymbol{x}^{(k)})$是$\boldsymbol{x}^{(k)}$处下降方向，该性质显然成立。

罚函数法

接下来，我们介绍一种能求解一般约束优化的算法：罚函数法

- 罚函数法基本思想：将有约束优化问题变为无约束优化问题，并通过罚因子的选择保证解的可行性。

无约束优化问题有以下形式

$$\min q(\boldsymbol{x}) = f(\boldsymbol{x}) + \gamma P(\boldsymbol{x})$$

其中$\gamma \in \mathbb{R}^+$是一个大于0的常数，称为**惩罚因子**，$P: \mathbb{R}^n \to \mathbb{R}$称为**罚函数**。

- 注意：部分资料将$q(\boldsymbol{x})$称为罚函数，$\gamma P(\boldsymbol{x})$称为罚项。

罚函数法

对于

$$\min q(\boldsymbol{x}) = f(\boldsymbol{x}) + \gamma P(\boldsymbol{x})$$

罚函数$P: \mathbb{R}^n \to \mathbb{R}$表示了对当前解违反约束的惩罚程度，一般满足以下三个条件：

1. $P(\boldsymbol{x})$是连续的，
2. 对所有$\boldsymbol{x} \in \mathbb{R}^n$,$P(\boldsymbol{x}) \geq 0$，
3. $P(\boldsymbol{x}) = 0$当且仅当x是可行点。

绝对值罚函数

例:

$$\begin{aligned} &\min f(\boldsymbol{x}) \\ \text{s.t. } &g_1(\boldsymbol{x}) \le 0 \\ &g_2(\boldsymbol{x}) \le 0 \\ &\dots \\ &g_p(\boldsymbol{x}) \le 0 \end{aligned}$$

其中$f: \mathbb{R}^n \to \mathbb{R},\ g_i: \mathbb{R}^n \to \mathbb{R}, i = 1, \dots, p$

我们可以构造函数:

$$P(\boldsymbol{x}) = \sum_{i=1}^{p} g_i^+(x)$$

其中

$$g_i^+(\boldsymbol{x}) = \max(0, g_i(x)) = \begin{cases} 0 & if\ g_i(x) \le 0 \\ g_i(x) & if\ g_i(x) > 0 \end{cases}$$

这种罚函数被称为绝对值罚函数。

绝对值罚函数

如$g_1(x) = x - 2 \leq 0$，$g_2(x) = -(x+1)^3 \leq 0$的绝对值罚函数为：

$$g_1^+(x) = \max(0, g_1(x)) = \begin{cases} 0 & if\ x \leq 2 \\ x - 2 & otherwise \end{cases}$$

$$g_2^+(x) = \max(0, g_2(x)) = \begin{cases} 0 & if\ x \geq -1 \\ -(x+1)^3 & otherwise, \end{cases}$$

$$P(x) = g_1^+(x) + g_2^+(x) = \begin{cases} x - 2 & if\ x > 2 \\ 0 & if\ -1 \leq x \leq 2 \\ -(x+1)^3 & if\ x < -1. \end{cases}$$

绝对值罚函数

$$P(x) = g_1^+(x) + g_2^+(x) = \begin{cases} x-2 & if\ x > 2 \\ 0 & if\ -1 \le x \le 2 \\ -(x+1)^3 & if\ x < -1. \end{cases}$$

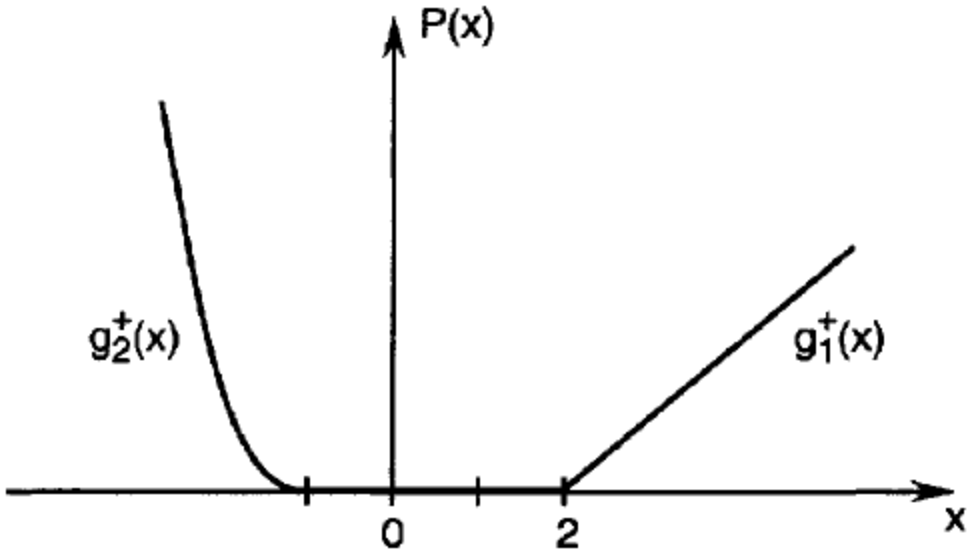

缺陷：不是处处可微，梯度法可能无法求解$\min f(\boldsymbol{x}) + \gamma P(\boldsymbol{x})$!

库朗-贝尔特拉米罚函数

- 库朗-贝尔特拉米罚函数

Courant-Beltrami罚函数

$$P(\boldsymbol{x}) = \sum_{i=1}^{p} (\max(g_i(\boldsymbol{x}), 0))^2$$

能使原函数$h_i(\boldsymbol{x}), g_i(\boldsymbol{x})$在定义域上处处可微。

对于

$$\min f(\boldsymbol{x})$$
$$s.t. h_i(\boldsymbol{x}) = 0, i = 1, \dots, m,$$
$$g_j(\boldsymbol{x}) \leq 0, j = 1, \dots, p$$

库朗-贝尔特拉米罚函数为

$$P(\boldsymbol{x}) = \sum_{i=1}^{m} \left(h_i(\boldsymbol{x})\right)^2 + \sum_{j=1}^{p} \left(\max\left(g_j(\boldsymbol{x}), 0\right)\right)^2$$

若$\boldsymbol{h}(\boldsymbol{x})$，$\boldsymbol{g}(\boldsymbol{x})$可微，则$P(x)$一阶可微，但是$P(x)$并不保证二阶可微。

罚函数举例

- 考虑等式约束优化问题

$$\min f(\boldsymbol{x}) = x_1^2 + x_2^2 \ , s.t. h(\boldsymbol{x}) = x_2 - 1 = 0$$

的罚函数$q(\boldsymbol{x}, \gamma) = x_1^2 + x_2^2 + \gamma(x_2 - 1)^2$

将γ看成一个常数，直接使用解析法求$q(\boldsymbol{x}, \gamma)$,那么$\nabla_x q = 0$

$$\frac{\partial q}{\partial x_1} = 2x_1 = 0, \quad \frac{\partial q}{\partial x_2} = 2x_2 + 2\gamma(x_2 - 1) = 0$$

$$\Rightarrow x_1^* = 0, x_2^* = \frac{\gamma}{1+\gamma}$$

当γ趋于无穷大时，最优解x_2^*最终收敛到1(最优解)，满足了约束。

γ	0	1	2	3	…	∞
x_2^*	0	1/2	2/3	3/5	…	1

外点法基本思想

对于包含等式和不等式的优化问题，我们介绍一种具体的罚函数法：**外部惩罚函数法，**也叫**外点法**

考虑优化问题

$$\min f(x) = x^2$$
$$s.t.\ g(x) = x + 1 \leq 0$$

不同γ值对应的罚函数，即

$$q(x,\gamma) = \begin{cases} x^2, x + 1 \leq 0 \\ x^2 + \dfrac{\gamma}{2}(x+1)^2, x + 1 \geq 0 \end{cases}$$

外点法基本思想

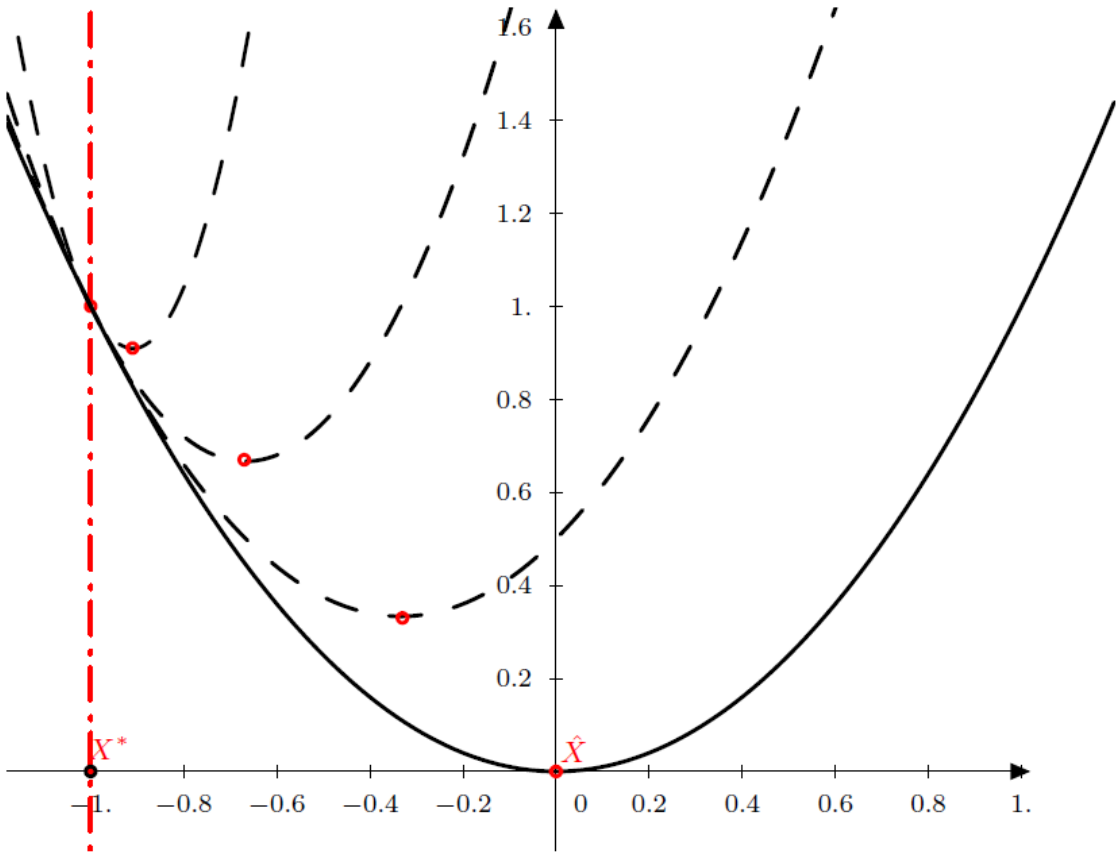

当 γ 从零逐渐增大时，函数 $q(x,\gamma)$ 就对应于上述逐渐拉起的曲线。可以设想当 γ 充分大时，$q(x,\gamma)$ 的无约束极小点 $\bar{x}$ 就会充分接近 x^*。

外点法基本思想

我们能直接求出 $q(x,\gamma)$ 的极小点。

$$\frac{\partial q}{\partial x} = 2x + \gamma(x+1) = 0$$

解得 $\bar{x}(\gamma) = \frac{-\gamma}{2+\gamma}$，当 $\gamma \to +\infty$ 时，$\bar{x}(\gamma) = -1 = x^*$，这与预期结果一致。

外点法基本思想

- 外部惩罚函数法（外点法）思想：构造新的无约束优化目标函数，对违反原问题约束的点在新目标函数中加入相应的“惩罚”，而对原问题可行域内的点不予惩罚。随着一个无约束问题的求解转到另一个无约束问题的求解，惩罚会逐次加大，从而迫使迭代点向可行域靠近。
- 此法的迭代点一般在可行域外部移动，也称为“外点法”

外点法

对于一般约束优化问题

$$\min f(\boldsymbol{x})$$
$$s.t.\, h_i(\boldsymbol{x}) = 0, i = 1, \dots, m$$
$$g_j(\boldsymbol{x}) \le 0, j = 1, \dots, p$$

其中$f: \mathbb{R}^n \to \mathbb{R}$，$m \le n$, 外点法一般利用库朗-贝尔特拉米罚函数构造无约束优化问题：

$$q(\boldsymbol{x}, \gamma_k) = f(\boldsymbol{x}) + \gamma_k \left\{ \sum_{i=1}^{m} \left(h_i(\boldsymbol{x})\right)^2 + \sum_{j=1}^{p} \left(\max\left(g_j(\boldsymbol{x}), 0\right)\right)^2 \right\}$$

设$P(\boldsymbol{x}) = \sum_{i=1}^{m} \left(h_i(\boldsymbol{x})\right)^2 + \sum_{j=1}^{p} \left(\max\left(g_j(\boldsymbol{x}), 0\right)\right)^2$

则无约束优化问题为

$$\min q(\boldsymbol{x}, \gamma_k) = f(\boldsymbol{x}) + \gamma_k P(\boldsymbol{x})$$

外点法

外点法基本步骤:

1. 选定初始点 $\boldsymbol{x}^{(0)}$；初始罚因子 $\gamma_1 > 0$，（取 $\gamma_1 = 1$），罚因子的放大系数 $C > 1$（取 $C = 10$）；置 $k = 1$。

2. 以 $\boldsymbol{x}^{(k-1)}$ 为初始点，求解无约束问题

$$\min\{f(\boldsymbol{x}) + \gamma_k P(\boldsymbol{x})\}$$

设其极小点 $\boldsymbol{x}^{(k)}$。

3. 若 $\gamma_k P\left(\boldsymbol{x}^{(k)}\right) < \epsilon$，则 $\boldsymbol{x}^{(k)}$ 就是所要求的最优解，打印 $\boldsymbol{x}^* = \boldsymbol{x}^{(k)}$，停机；否则转（4）。

4. 置 $\gamma_{k+1} = C\gamma_k; k = k + 1$，转（2）。

- 在求解无约束问题 $\min\{f(\boldsymbol{x}) + \gamma_k P(\boldsymbol{x})\}$ 时，若函数均可微，可以采用DFP法、BFGS法或改进的牛顿法。

外点法

例：外点法求解

$$\min f(\boldsymbol{x}) = x_1 + x_2$$
$$s.t. -x_1^2 + x_2 \geq 0$$
$$x_1 \geq 0$$

解：标准型$g_1(\boldsymbol{x}) = x_1^2 - x_2$， $g_2(\boldsymbol{x}) = -x_1$

构造罚函数 $q(\boldsymbol{x}, \gamma) = x_1 + x_2 + \gamma\{[\max(0, x_1^2 - x_2)]^2 + [\max(0, -x_1)]^2\}$

$$\frac{\partial q}{\partial x_1} = 1 + 2\gamma\left[\max\left(0, (x_1^2 - x_2)(2x_1)\right)\right] - 2\gamma[\max(0, -x_1)]$$

$$\frac{\partial q}{\partial x_2} = 1 + 2\gamma[\max(0, -(x_1^2 - x_2))]$$

对于不满足约束条件的 $\boldsymbol{x} = (x_1, x_2)^T$ 有

$$x_1^2 - x_2 > 0, -x_1 > 0$$

令 $\frac{\partial q}{\partial x_1} = \frac{\partial q}{\partial x_2} = 0$，得 $\min q(\boldsymbol{x}, \gamma)$ 的解为

$$\boldsymbol{x}(\gamma) = \left(-\frac{1}{2(1+\gamma)}, \left(\frac{1}{4(1+\gamma)^2} - \frac{1}{2\gamma}\right)\right)^T$$

外点法

取 $\gamma_1 = 1, \boldsymbol{x} = \left(-\frac{1}{4}, -\frac{7}{16}\right)^T$

$\gamma_2 = 2, \boldsymbol{x} = \left(-\frac{1}{6}, -\frac{2}{9}\right)^T$

$\gamma_3 = 3, \boldsymbol{x} = \left(-\frac{1}{8}, -\frac{29}{192}\right)^T$

$\gamma_4 = 4, \boldsymbol{x} = \left(-\frac{1}{10}, -\frac{23}{200}\right)^T$

$\boldsymbol{x}(\gamma)$ 从 $\mathbb{R}$ 的外面逐步逼近 $\mathbb{R}$ 的边界，当 $\gamma \to \infty$ 时，$\boldsymbol{x}(\gamma)$ 趋于原问题极小解 $\boldsymbol{x}^* = (0,0)^T$。

外点法的收敛性

- 设 $\{\boldsymbol{x}^{(k)}\}$ 是由外点法所产生的序列，则

(1) $q\left(\boldsymbol{x}^{(k+1)}, \gamma_{k+1}\right) \geq q\left(\boldsymbol{x}^{(k)}, \gamma_k\right)$

(2)$P\left(\boldsymbol{x}^{(k+1)}\right) \leq P\left(\boldsymbol{x}^{(k)}\right)$

(3)$f\left(\boldsymbol{x}^{(k+1)}\right) \geq f\left(\boldsymbol{x}^{(k)}\right)$ 其中 $k \geq 1$。

- 设 $f, h_1, h_2, \cdots, h_m$和$g_1, g_2, \cdots, g_p$ 都是 $\mathbb{R}^n$ 上的连续函数，则由外点法所产生的任何收敛序列 $\{\boldsymbol{x}^{(k)}\}$ 的极限点必是约束最优化问题式的极小点。

外点法的优缺点

- 外点法的优势：对等式约束和非凸规划均适用，且初始点 $\boldsymbol{x}^{(0)}$ 可以任取，这就为求解非凸规划问题的全局极值提供了一种方法。
- 缺点：在迭代中 $\boldsymbol{x}^{(k)}$ 一般不属于可行解，只有到最后才能得到解（可行）；罚因子 γ_k 要求最终取到很大才行，但这样得到的无约束问题一般是病态的，给求解带来了困难。
- 又要减少求解无约束问题的困难，又要惩罚因子较小，怎样选取合适的惩罚因子 γ_k是值得研究的，可参考增广拉格朗日函数法。

内点法

- 内点法也称为障碍法(Barrier method)，它将目标函数改造为**障碍函数**$q(\boldsymbol{x},r)=f(\boldsymbol{x})+\gamma P(\boldsymbol{x})$，其中$P(\boldsymbol{x})$是一个类似罚函数的惩罚项。
- 不同于罚函数，若$\boldsymbol{x}$在可行集内部且与边界比较远，$q(\boldsymbol{x},\gamma)$接近$f(\boldsymbol{x})$；而如果$\boldsymbol{x}$接近边缘，则$P(\boldsymbol{x})$可以是任意大的值，$q(\boldsymbol{x},\gamma)$也变成任意大。使用迭代算法，$\boldsymbol{x}$从一个内点出发，对$q(\boldsymbol{x},\gamma)$进行无约束优化，障碍函数能保证极小值不跑出约束集。
- 我们主要介绍内点法用于解决以下不等式优化问题:

$$\min f(\boldsymbol{x})\ \ s.t.\, g_i(\boldsymbol{x})\le 0, i=1,\dots,p$$

其中$\boldsymbol{x}\in\mathbb{R}^n$，$f(\boldsymbol{x})$连续可微。

内点法

障碍函数$q(\boldsymbol{x},\gamma)=f(\boldsymbol{x})+\gamma P(\boldsymbol{x})$中$\gamma\in\mathbb{R}^{+}$是障碍因子，$P(\boldsymbol{x})$为障碍项。常见障碍函数：

- Power barrier:

$$q(x,\gamma)=f(x)+\gamma\sum_{i=1}^{p}\left(-g_i(x)\right)^{-t}\ ,t>1$$

- Logarithm barrier:

$$q(x,\gamma)=f(x)-\gamma\sum_{i=1}^{p}\ln\left(-g_i(x)\right)$$

- Exponential barrier:

$$q(x,\gamma)=f(x)+\gamma\sum_{i=1}^{p}\exp(-\frac{1}{g_i(x)})$$

内点法

我们将考虑如下障碍函数

$$q(\boldsymbol{x},\gamma)=f(\boldsymbol{x})+\gamma\sum_{i=1}^{p}\frac{1}{-g_i(\boldsymbol{x})}$$

考虑某个$\gamma\geq 0$， $\boldsymbol{x}^{(k)}=\underset{\boldsymbol{x}\in\mathbb{R}^n}{argmin}\, q(\boldsymbol{x},\gamma)$。

若$\boldsymbol{x}^{(k)}$是约束集的一个内点，且距离边界较远，$g_i(x)<0$，这时候惩罚项将很小。

将$\boldsymbol{x}^{(k)}$由约束集内部逐步移动接近边界时，$g_i(\boldsymbol{x})\to 0$，则$P(\boldsymbol{x},\gamma)$变得迅速变大，$\boldsymbol{x}^{(k)}$不再可能是$q(\boldsymbol{x},\gamma)$的极小解，这也就阻止了$\boldsymbol{x}^{(k)}$越过边界。

内点法

基于上述考虑，我们得到如下内点法：

1. 选择初始点$\boldsymbol{x}^{(0)}$，要求$\boldsymbol{x}^{(0)}$必须是内点；选择初始惩罚因子$\gamma_1 > 0$（如，可取$\gamma_1 = 10$）,惩罚因子缩小系数$C < 1$；置$k = 1$。
2. 以$\boldsymbol{x}^{(k-1)}$为初始点，求解无约束优化问题。$\min f(\boldsymbol{x}) + \gamma_k P(\boldsymbol{x})$。设找到的极小点为$\boldsymbol{x}^{(k)}$。
3. 若$\gamma_k P(\boldsymbol{x}) < \varepsilon$，则$\boldsymbol{x}^{(k)}$就是所求的最优解，停机；否则进入下一步。
4. $\gamma_{k+1} = C\gamma_k$,转（2）。

内点法举例

例:

$$\min f(\boldsymbol{x}) = \frac{1}{3}(x_1+1)^3 + x_2$$
$$s.t.\, g_1(x) = 1 - x_1 \le 0$$
$$g_2(x) = -x_2 \le 0$$

解:

$$q(x,\gamma_k) = \frac{1}{3}(x_1+1) + x_2 + \frac{\gamma_k}{x_1-1} + \frac{\gamma_k}{x_2}$$
$$\frac{\partial q}{\partial x_1} = (x_1+1)^2 - \frac{\gamma_k}{(x_1-1)^2} = 0$$
$$\frac{\partial q}{\partial x_2} = 1 - \frac{\gamma_k}{x_2^2} = 0$$
$$\Rightarrow \boldsymbol{x}^{(k)} = \left(\sqrt{1+\sqrt{\gamma_k}}, \sqrt{\gamma_k}\right)^T$$

最优解$x^* = \lim_{\gamma_k \to 0} \boldsymbol{x}^{(k)} = \lim_{r_k \to 0} \left(\sqrt{1+\sqrt{\gamma_k}}, \sqrt{\gamma_k}\right)^T = (1,0)^T$

内点法举例

初始罚因子取 $\gamma_1 = 9$，令 $\frac{\gamma_{k+1}}{\gamma_k} = C = \frac{1}{2}$，点列在可行域内逐步向最优点 $\boldsymbol{x}^* = (1,0)^T$ 逼近的过程如下

k	γ_k	$x_1^*(\gamma_k)$	$x_2^*(\gamma_k)$	$f(\boldsymbol{x}_k^*)$
1	9	2	3	12
2	4.5	1.767	2.12	9.18931
3	2.25	1.581	1.50	7.23116
4	1.125	1.439	1.60	5.89631
5	0.563	1.322	0.752	4.92516
6	0.282	1.229	0.503	4.19455
7	0.141	1.710	0.376	3.78210
8	0.707	1.120	0.257	3.43304
9	0.036	1.091	0.190	3.23748
10	0.018	1.026	0.134	3.05643
11	0.009	1.047	0.095	2.95413
∞	0	1.0	0	2.6667 $= 8/3$

内点法举例

- 例：用对数障碍函数

$$q(\boldsymbol{x},\gamma_k) = f(\boldsymbol{x}) - \gamma_k \sum_{i=1}^{p} \ln(-g_i(\boldsymbol{x}))$$

求解

$$\min f(\boldsymbol{x}) = x_1 + 2x_2$$
$$s.t.\ g_1(\boldsymbol{x}) = x_1^2 - x_2 \leq 0$$
$$g_2(\boldsymbol{x}) = -x_1 \leq 0$$

内点法举例

构造障碍函数

$$q(\boldsymbol{x},\gamma_k) = x_1 + 2x_2 - \gamma_k \ln(-x_1^2 + x_2) - \gamma_k \ln x_1$$

$$\begin{cases} \dfrac{\partial q}{\partial x_1} = 1 + \dfrac{2\gamma_k x_1}{-x_1^2 + x_2} - \dfrac{\gamma_k}{x_1} = 0 \\ \dfrac{\partial q}{\partial x_2} = 2 - \dfrac{\gamma_k}{-x_1^2 + x_2} = 0 \end{cases}$$

解得

$$x_1^*(\gamma_k) = \frac{1}{8}\left(-1 + \sqrt{1 + 16\gamma_k}\right)$$

$$x_2^*(\gamma_k) = \frac{1}{64}\left(-1 + \sqrt{1 + 16\gamma_k}\right)^2 + \frac{1}{2}\gamma_k$$

当 $r_k \to 0$ 时，$\boldsymbol{x}^*(r_k) \to (0,0)^T = \boldsymbol{x}^*$

内点法举例

下表给出了初始罚因子 $\gamma_1 = 4$，$\frac{\gamma_{k+1}}{\gamma_k} = 0.5 = C$的迭代情况

k	γ_k	$x_1^*(\gamma_k)$	$x_2^*(\gamma_k)$	$f(\boldsymbol{x}^*(\gamma_k))$
1	4	0.885	2.781	6.447
2	2	0.593	1.35	3.293
3	1	0.391	0.653	1.697
4	0.5	0.375	0.39	1.155
5	0.25	0.155	0.149	0.453
6	0.125	0.090	0.071	0.232
7	0.063	0.057	0.035	0.127
8	0.032	0.029	0.017	0.063
9	0.016	0.016	0.008	0.032
10	0.008	0.008	0.004	0.016
11	0.004	0.003	0.002	0.007
∞	0	0	0	0

内点法收敛性

- 由内点算法所产生的序列 $\{\boldsymbol{x}^{(k)}\}$，总有

$$q\left(\boldsymbol{x}^{(k+1)},\gamma_{k+1}\right) \leq q\left(\boldsymbol{x}^{(k)},\gamma_k\right) \quad k \geq 1$$

- 内点法的收敛性：目标函数f，g_{i}，h_i是$\mathbb{R}^n$上的连续函数，当$k \to \infty$，$\gamma_k \to 0$时，由内点法产生的任意收敛序列$\{x^{(k)}\}$的极限点是约束优化问题的一个解。

内点法优缺点

- 对比内点法和外点法：

1. 外点法惩罚函数虽然存在一阶连续偏导数，但是二阶偏导数在可行集边界不存在，这种限制导致不能使用部分需要二阶连续可微无约束优化算法；而内点法障碍函数的可微阶数与$g_i(\boldsymbol{x})$相同。
2. 外点法只有到最后才能获得可行解；而内点法的中间结果均为可行解，使得我们可以随时停机并仍旧能获取质量不错的解。

小结

- 投影法原理，投影梯度法以及其在线性约束问题中的应用

$$\boldsymbol{P} = \boldsymbol{I}_n - \boldsymbol{A}^{\boldsymbol{T}}(\boldsymbol{A}\boldsymbol{A}^{\boldsymbol{T}})^{-\boldsymbol{1}}\boldsymbol{A}$$

$$\Pi\left[\boldsymbol{x}^{(\boldsymbol{k})} - \alpha_k \boldsymbol{\nabla f}\left(\boldsymbol{x}^{(\boldsymbol{k})}\right)\right] = \boldsymbol{x}^{(\boldsymbol{k})} - \alpha_k \boldsymbol{P}\nabla f\left(x^{(k)}\right)$$

- 外点法（罚函数法）原理，步骤，收敛性。
- 内点法（障碍法）原理，步骤，收敛性。

谢 谢
THANKS